УДК 659.118
ББК 32.973.26
Н90

Нурматова Е.В. Аналитическая обработка структурированных данных: инструменты и примеры применения [Электронный ресурс]: Учебное пособие / Нурматова Е.В., Зайцев Е.И. — М.: МИРЭА — Российский технологический университет, 2025. — 1 электрон. опт. диск (CD-ROM)

Учебное пособие посвящено аналитической обработке структурированных данных, охватывает базовые методы работы с данными и современные инструменты для их анализа и визуализации. Материал разделен на три раздела, каждый из которых рассматривает определенный аспект аналитической обработки. Первая часть знакомит с основами анализа данных: сводными таблицами, реализации с их помощью RFM-анализа, исследовательской подготовкой данных, применением Simple ML для автоматизации машинного обучения. Вторая часть рассматривает возможности SQL-запросов для эффективного решения задач аналитики, формирования гибких отчетов и проведения предварительной подготовки данных, минимизируя дополнительную необходимость в этом за пределами базы данных. Третья часть фокусируется на обзоре комплексных аналитических платформах, которые поддерживают полный цикл анализа данных — от предобработки до интерпретации результатов. Особое внимание уделяется средствам для визуализации данных и создания интерактивных аналитических дашбордов. Пособие будет полезно аналитикам данных, а также всем, кто интересуется современными подходами к обработке и визуализации структурированных данных.

Учебное пособие соответствует учебной программе дисциплины «Технологии и инструменты систем управления данных», «Модели и методы принятия технических решений» и предназначен для студентов всех форм обучения направления подготовки 09.03.02 «Информационные системы и технологии».

Учебное пособие издаётся в авторской редакции.

Авторский коллектив: Нурматова Елена Вячеславовна, Зайцев Евгений Игоревич

Рецензенты:

Лебедев Георгий Станиславович, д.т.н., директор Центра цифровой медицины, зав. кафедрой информационных технологий и обработки медицинских данных Первого МГМУ им. И.М. Сеченова

Леонов Анатолий Петрович, к.т.н., доцент кафедры автоматизации технологических процессов и производств филиала «Протвино» государственного университета «Дубна»

Системные требования:
Наличие операционной системы Windows, поддерживаемой производителем.
Наличие свободного места в оперативной памяти не менее 128 Мб.
Наличие свободного места в памяти постоянного хранения (на жестком диске) не менее 30 Мб.
Наличие интерфейса ввода информации.
Дополнительные программные средства: программа для чтения pdf-файлов (Adobe Reader).
Подписано к использованию по решению Редакционно-издательского совета
МИРЭА — Российский технологический университет.
Обьем: 3.22 мб
Тираж: 10

ISBN 978-5-7339-2606-3

© Нурматова Е.В., Зайцев Е.И., 2025
© МИРЭА – Российский
технологический университет, 2025

FreeBusta is knowledge
without borders!

ОГЛАВЛЕНИЕ

ВВЕДЕНИЕ 4
1. АНАЛИТИКА ОТ ПРОСТОГО К СЛОЖНОМУ 6
1.1.Основы работы со сводными таблицами 6
1.2.RFM-анализ данных сводных таблиц для сегментации 10
1.3.Simple ML для автоматизации процессов машинного обучения 14
1.4.Разведочный анализ с Mitosheet 19
2. ОКОННЫЕ ФУНКЦИИ И МНОГОМЕРНАЯ АГРЕГАЦИЯ 26
2.1. Язык запросов для извлечения и обработки данных 26
2.2. Агрегация со скользящим окном 28
2.3. Ранжирование и смещение в группах данных 32
2.4. Многомерная агрегация: комплексный взгляд на данные 36
3. ИНСТРУМЕНТЫ ДЛЯ АВТОМАТИЗАЦИИ МАШИННОГО ОБУЧЕНИЯ И СОЗДАНИЯ ИНТЕРАКТИВНЫХ ОТЧЕТОВ 40
3.1. Автоматическое машинное обучение с H2O Flow 40
3.2. Взаимодействие с данными и процессами в RapidMiner 46
3.3. Сценарий обработки данных в Loginom 50
3.4. Инструменты платформы KNIME Analytics Platform 56
3.5. Аналитические технологии Power BI 61
3.6. Визуализация данных в Yandex DataLens 67
ЗАКЛЮЧЕНИЕ 74
СПИСОК ИСТОЧНИКОВ И ЛИТЕРАТУРЫ 75

FreeBusta is knowledge
without borders!



ВВЕДЕНИЕ

В последние годы объёмы данных стремительно увеличились, технологии их обработки, хранения и управления непрерывно эволюционируют. Базы данных демонстрируют беспрецедентную скорость работы, а инструменты для анализа, отчетности и визуализации данных стали значительно эффективнее и функциональнее. В связи с этим возникает потребность в подготовке специалистов, которые смогут уверенно работать с современными технологиями и использовать их потенциал для решения практических задач.

Основная цель учебного пособия - предоставить читателям теоретические знания и практические навыки, необходимые для эффективной работы с данными, анализа информации и применения современных инструментов машинного обучения, которое бы позволило самостоятельно и правильно развиваться в рамках данного направления.

Пособие содержит теоретический и практический материал для изучения действенных механизмов, используемых на различных этапах работы с данными от загрузки и предобработки до создания, оценки и внедрения моделей машинного обучения.

Освоив материал учебного пособия, студенты смогут:

- работать с данными на базовом уровне: применять сводные таблицы в задаче сегментации, выполнять предподготовку данных и выполнять прогнозирование с использованием надстройки Simple ML;
- формулировать сложные аналитические запросы: использовать оконные функции, функции ранжирования и смещения, а также расширенные возможности группировки, упрощая создание многоуровневых отчетов, включая подитоги и общие итоги, для анализа многомерных данных;
- использовать современные аналитические платформы: работать с комплексными инструментами для автоматизации машинного обучения и поддержки полного цикла анализа данных — от предобработки до интерпретации результатов;
- создавать интерактивные дашборды: легко настраивать и обновлять в режиме реального времени.

При работе над учебным пособием для демонстрации упражнений были использованы следующие инструменты платформ:

FreeBusta is knowledge
without borders!

— открытая платформа (дистрибутив) для науки о данных и машинного обучения, интегрированная среду для работы с данными **Anaconda** (*https://www.anaconda.com/download)*

— набор инструментов или библиотек, которые позволяют автоматизировать и упростить процессы машинного обучения на начальном уровне **Simple ML** (*https://simplemlforsheets.com*)

— веб-интерфейс и платформа для работы с **H2O Flow** - открытой программной средой для автоматического подбора моделей и их гиперпараметров, лучших моделей для задач классификации, регрессии и других типов анализа (*https://h2o-release.s3.amazonaws.com/h2o/rel-yates/5/index.html*)

— интегрированные платформы для анализа данных, машинного обучения с drag-and-drop интерфейсом, что позволяет создавать рабочие процессы (pipelines) без написания кода: **RapidMiner** (*https://my.rapidminer.com/nexus/account/index.html#login?returnUrl=https%3A%2F%2Fmy.rapidminer.com%2Fnexus%2Facount%2Findex.html%23home*); **Loginom** (*https://loginom.ru/download*); **KNIME** (*https://www.knime.com/downloads*). Есть академическая программа для студентов и преподавателей.

— мощные инструменты для создания интерактивных дашбордов, позволяющие пользователям подключаться к различным источникам данных, преобразовывать их, строить отчеты: **Power BI Desktop** с возможностью публиковать результаты на платформе Power BI Service для совместного использования с другими пользователями (*https://www.microsoft.com/ru–ru/download/details.aspx?id=58494*); **Yandex Datalens**, легко интегрируемый с сервисами Яндекса, такими как Yandex Metrica, Yandex Cloud и другими (*https://yandex.cloud/ru/services/datalens*)

— объектно-реляционная система управления базами данных **PostgreSQL** *(https://postgrespro.ru)* и графический клиент **pgAdmin** (*https://www.pgadmin.org/download/*)

FreeBusta is knowledge
without borders!

1. АНАЛИТИКА ОТ ПРОСТОГО К СЛОЖНОМУ

Первая часть учебного пособия познакомит читателя с фундаментальными аспектами анализа данных, предлагая как теоретические основы, так и практические инструменты для работы с данными. Внимание уделено ключевым методам, которые позволяют эффективно обрабатывать и анализировать информацию. Среди них — работа со сводными таблицами, которые являются мощным инструментом для агрегации и визуализации данных, особенно при решении задач бизнес-аналитики.

Отдельный раздел посвящен проведению RFM-анализа, который широко используется для сегментации клиентов на основе их поведения. Этот метод помогает выявить наиболее ценных клиентов, определить группы для целевого маркетинга и разработать стратегии удержания.

Особое внимание в первой части уделяется применению набора функций Simple ML, который представляет собой инструмент для автоматизации процессов машинного обучения на начальном уровне. Этот инструмент позволяет пользователям без глубоких знаний программирования создавать базовые модели, выполнять предобработку данных и оценивать результаты. Таким образом, Simple ML становится отправной точкой для тех, кто только начинает изучать машинное обучение, предоставляя возможность быстро получить практические навыки и интуитивно понять основные принципы работы с моделями.

Кроме того, рассматривается исследовательский анализ данных (Exploratory Data Analysis, EDA) с использованием популярных Python-библиотек. EDA позволяет глубже понять структуру данных, выявить аномалии, закономерности и взаимосвязи между переменными, что является важным этапом подготовки данных для дальнейшего моделирования.

1.1. Основы работы со сводными таблицами

Рассмотрим правила построения сводных таблиц (pivot table), используя такие инструменты как Excel и Google. Сводные таблицы являются довольно распространенным инструментом анализа данных, идеально подходят для создания дашбордов. Они отображают данные в интерактивном виде, переводят представление двумерных структурированных данных в разных разрезах, в виде, удобном для анализа, упрощая поиск сравнений, закономерностей и тенденций.

Своё название сводные таблицы получили от возможности интерактивного «перетаскивания» полей, что позволяет динамически изменять внешний вид, давая аналитику новый ракурс при использовании того же источника данных.

FreeBusta is knowledge
without borders!



Можно создать сводную таблицу на внешнем источнике данных, хранящихся за пределами Excel. Можно получить внешние данных из разных источников и объединить их для дальнейшего построения сводной таблицы. В разделе коснёмся именно этого вопроса, ведь при работе с другими аналитическими инструментами такие действия будут наиболее актуальными.

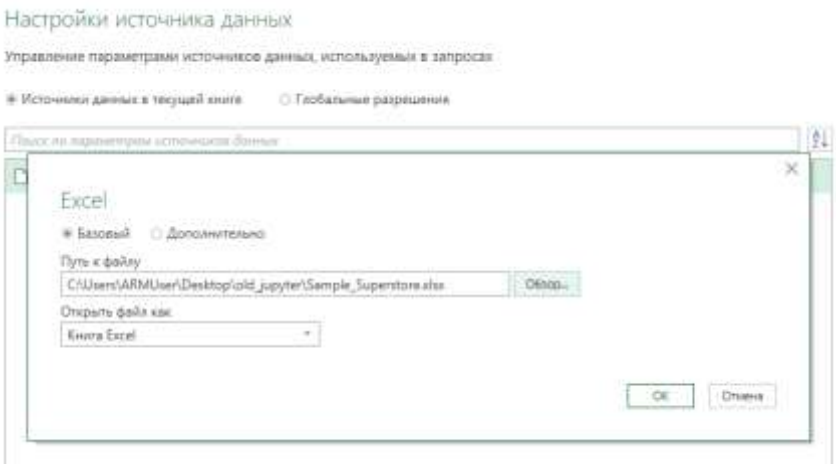


Рисунок 1.1. Настройка источника данных

Модель данных позволяет связывать таблицы между собой, создавая единое пространство для выполнения сложных вычислений, построения сводных таблиц и визуализации данных. Рассмотрим основные шаги и методы выполнения объединения данных.

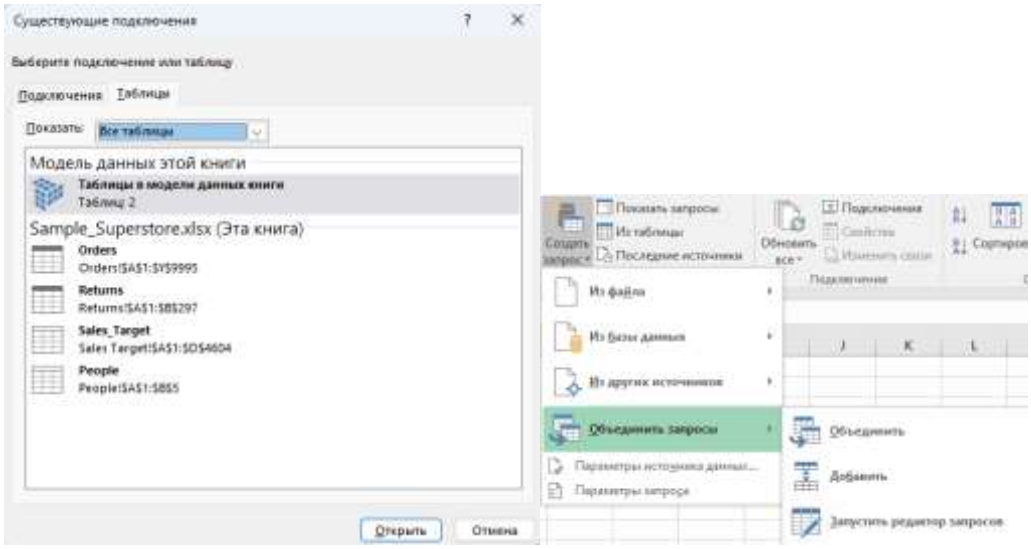


Рисунок 1.2. Объединение данных

Перед объединением таблиц важно убедиться, что данные структурированы корректно, а именно: каждая таблица имеет уникальные заголовки столбцов, данные организованы без пустых строк или столбцов, в таблицах должны

FreeBusta is knowledge
without borders!

присутствовать ключевые столбцы, которые будут использоваться для связи. Например, order_id в таблицах orders и returns, как показано на рис. 1.3.

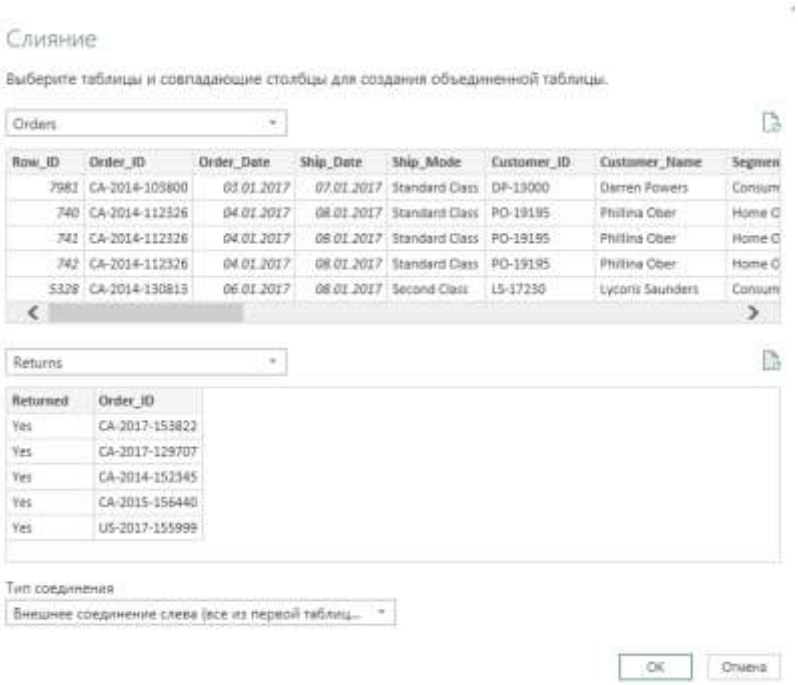


Рисунок 1.3. Слияние данных

При создании сводной таблицы, включающей поля из разных таблиц, будет запущен процесс автообнаружения связей. При необходимости можно создать самостоятельно ручную отношения между таблицами.

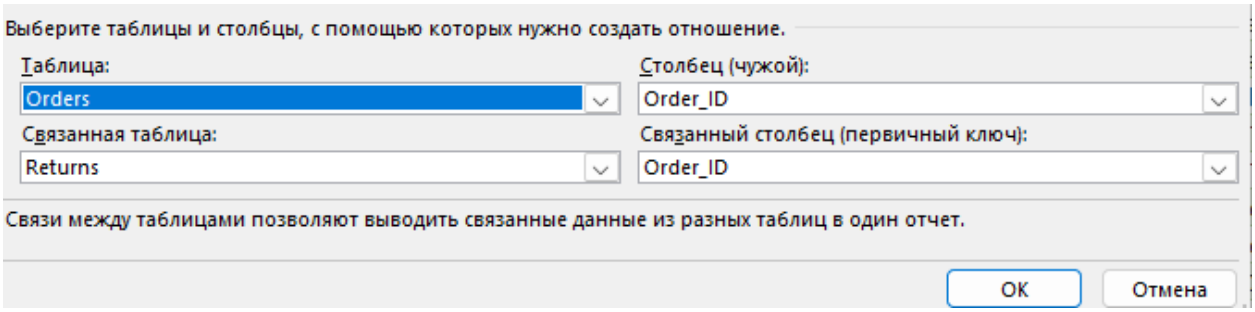


Рисунок 1.4. Настройка параметров соединения

FreeBusta is knowledge
without borders!

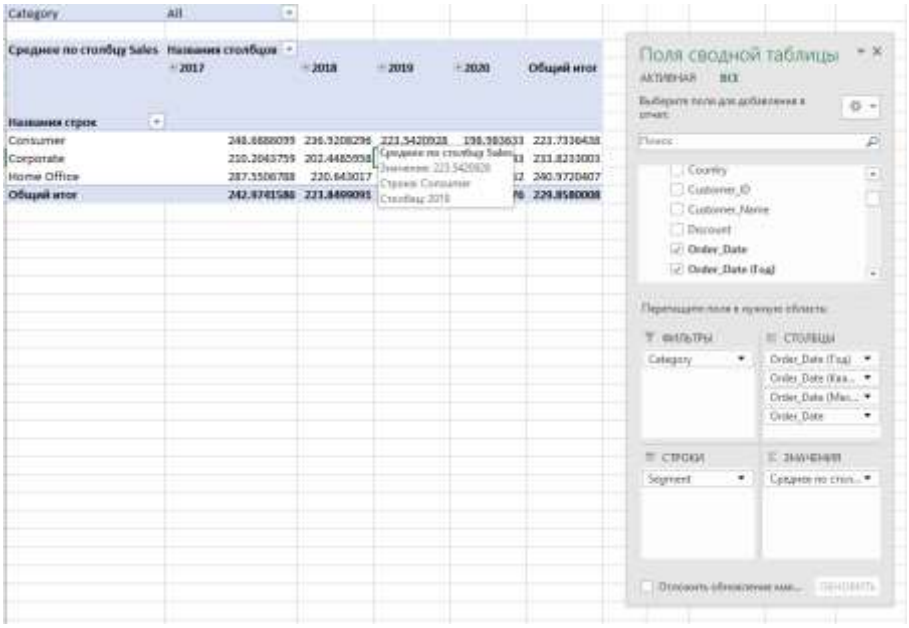


Рисунок 1.5. Формирование макета сводной таблицы

Если данные имеют один и тот же источник, то можно использовать временную шкалу для фильтрации сразу по нескольким сводным таблицам.

Если нужно объединить срезы с временной школой для фильтрации одного и того же поля даты, то используем разрешение нескольких фильтров для поля диалоге при настройке параметров сводной таблицы (*Работа со сводными таблицами → Анализ → Параметры → Итоги и фильтры*).

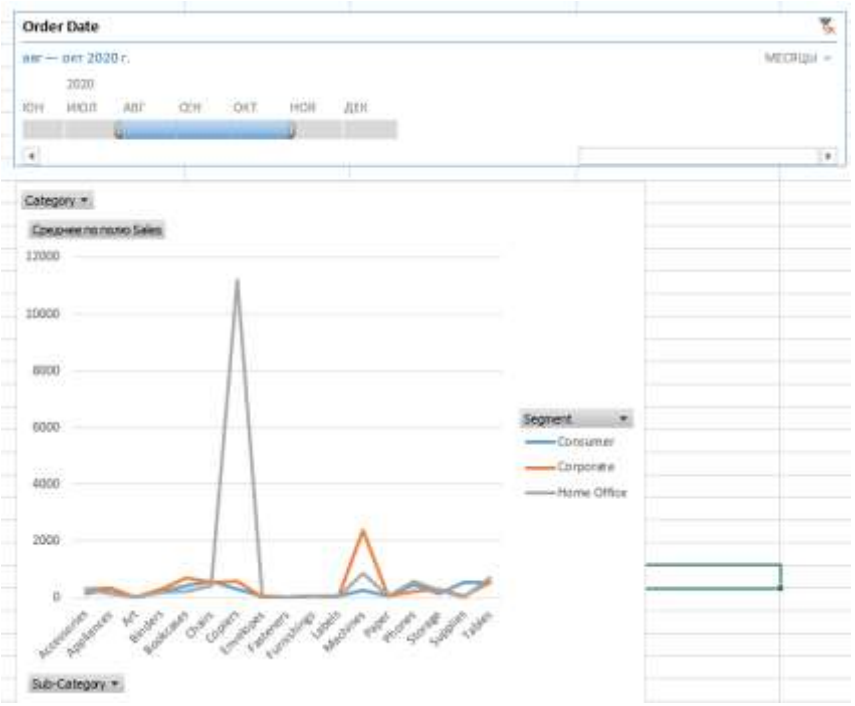


Рисунок 1.6. Шкалы фильтрации

FreeBusta is knowledge
without borders!

Если требуется дополнительная гибкость, можно использовать язык DAX (Data Analysis Expressions) для создания вычисляемых столбцов, мер и пользовательских формул: вычисляемые столбцы добавляют новые данные на основе существующих, меры используются для агрегации данных.

1.2. RFM-анализ данных сводных таблиц для сегментации

RFM-анализ — метод сегментации клиентской базы, который поможет грамотно выстроить маркетинговую стратегию, другими словами, позволяет понять, какая категория клиентов тратит у вас много и регулярно, какая — часто, но понемногу, и кто давно к вам не возвращался. Конечная его цель — перевести как можно больше клиентов в категорию постоянных и увеличить продажи.

Recency (давность) — этот показатель демонстрирует, как давно клиенты приобретали ваши товары или пользовались вашими услугами.

Frequency (частота) — с какой периодичностью клиенты обращаются за вашими товарами или услугами.

Monetary (деньги) — сколько всего у вас тратят.

Для проведения RFM-анализа нужно собрать данные обо всех покупках. По каждому из трёх показателей клиентскую базу делят на три группы:

RECENCY/ДАВНОСТЬ	FREQUENCY/ЧАСТОТА	MONETARY/ДЕНЬГИ
Клиент был недавно	Частые покупки	Высокий чек
«Засыпающий» клиент	Редкие покупки	Средний чек
Был очень давно	Разовая покупка	Низкий чек

Рисунок 1.7. Основные категории компонентов RFM-модели

Такая классификация помогает эффективно сегментировать клиентов и разрабатывать стратегии маркетинга или удержания.

Главное преимущество RFM-анализа — его можно сделать бесплатно с помощью таблиц в Excel, Google Sheets или специальных сервисов.

Например, последняя версия Excel поддерживает до миллиона строк, и для небольшого бизнеса этого вполне хватит. Если у вас в выгрузке больше миллиона строк, то Excel не подойдёт — придётся использовать более профессиональные инструменты.

Для анализа придётся корректно выгрузить данные из базы или CRM-системы: идентификаторы покупателей — например, фамилии или id, даты покупок (сделок), суммы покупок и далее применить формулы, которые позволят рассчитать дату с последней покупки каждого покупателя и другие показатели.

FreeBusta is knowledge
without borders!

В завершение анализа можно сделать в Excel форматирование, которое «окрашивает» в разные цвета различные сегменты аудитории. Это позволяет наглядно увидеть, в каком состоянии находится ваша клиентская база.

Применительно к продажам закон Парето означает, что 20% клиентов приносят 80% продаж. RFM-анализ помогает выявить эти 20% — лояльных платёжеспособных клиентов, самую перспективную часть аудитории, на которую эффективнее всего направлять рекламные ресурсы.

Для начала создаётся и настраивается сводная таблица так, чтобы вычислить количество обращений клиента по поводу заказа и дату последнего обращения. Сколько раз клиент заказывал — перетягиваем столбец с CustomerID и значение количества по полю InvoiceNo. Так мы видим, сколько заказов по каждому ID; на какую сумму клиент заказывал — значение суммы по полю Monetary; когда клиент в последний раз заказывал — значение максимума по полю InvoiceDate:

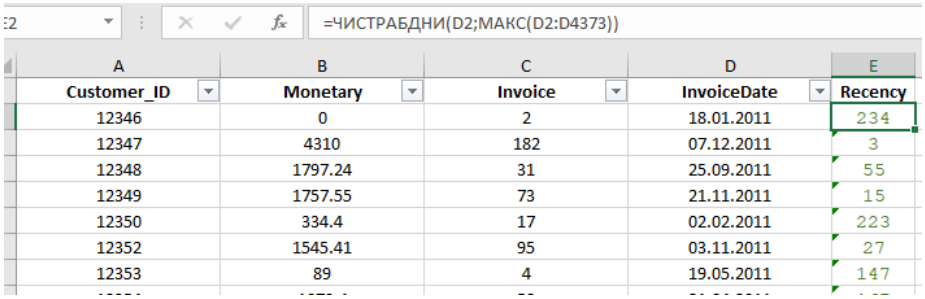


Названия строк	Сумма по полю Monetary	Количество по полю Invoice	Максимум по полю InvoiceDate
12346	0	2	18.01.2
12347	4310	182	07.12.2
12348	1797.24	31	25.09.2
12349	1757.55	73	21.11.2
12350	334.4	17	02.02.2
12352	1545.41	95	03.11.2
12353	89	4	19.05.2
12354	1079.4	58	21.04.2
12355	459.4	13	09.05.2
12356	2811.43	59	17.11.2
12357	6207.67	131	06.11.2
12358	1168.06	19	08.12.2
12359	6245.53	254	02.12.2
12360	2662.06	129	18.10.2
12361	189.9	10	25.02.2
12362	5154.58	274	06.12.2
12363	552	23	22.08.2
12364	1313.1	85	02.12.2
12365	320.69	23	21.02.2
12367	168.9	11	05.12.2
12370	3545.69	167	19.10.2
12371	1887.96	63	26.10.2
12372	1298.04	52	29.09.2
12373	364.6	14	01.02.2
12374	742.93	33	14.11.2
12375	455.42	18	07.12.2
12377	1628.12	77	28.01.2
12378	4008.62	219	02.08.2
12379	850.29	41	19.09.2

Рисунок 1.8. Формирование сводной таблицы

Скопируем данные на новый лист, переименуем поля в читаемый вид и для удобства поменяем порядок столбцов. В отдельном столбце рассчитаем, сколько дней прошло с последнего заказа для максимальной даты в датасете:

FreeBusta is knowledge without borders!



=ЧИСТРАБДНИ(D2;МАКС(D2:D4373))

	A	B	C	D	E
	Customer_ID	Monetary	Invoice	InvoiceDate	Recency
	12346	0	2	18.01.2011	234
	12347	4310	182	07.12.2011	3
	12348	1797.24	31	25.09.2011	55
	12349	1757.55	73	21.11.2011	15
	12350	334.4	17	02.02.2011	223
	12352	1545.41	95	03.11.2011	27
	12353	89	4	19.05.2011	147

Рисунок 1.9. Ввод формулы для вычисления давности

Далее рассчитаем ранг клиента по признаку Сумма заказа (Monetary), столбец назовём Monetary Score, для чего можно использовать функцию ПРОЦЕНТРАНГ. Функция возвращает ранг значения в наборе данных как процентное содержание в наборе данных (от 0 до 1, включая эти числа). Эта функция используется для оценки относительного положения значения в наборе данных.

Аналогично вычисляем ранг клиента по частоте покупок (Frequency) и по их давности (Recency). В последнем случае лучшими клиентами будут те, у которых давность меньше. Следующим шагом суммируем полученные ранги и создадим итоговое поле RFM.

Рассчитаем ранг клиента по признаку RFM, получим поле RFM Score и сопоставим ранг с сегментом клиента, используя для поиска объектов в таблице функцию ВПР .

F	G	H	I	J	K	L	M	N	O
MS	FS	RS	RFM	RFM Score	Segment			RFM Score	Customer Segment
0	0	0	0	0	Doesn't			10	Top
9	8	9	26	9	Top			9	Top
7	4	3	14	5	Loyal			8	Top
7	6	7	20	7	Loyal			7	Loyal
2	2	0	4	0	Doesn't			6	Loyal
7	7	5	19	7	Loyal			5	Loyal
0	0	1	1	0	Doesn't			4	Risk
6	5	1	12	4	Risk			3	Risk
3	1	1	5	1	Doesn't			2	Risk
8	6	6	20	7	Loyal			1	Doesn't
9	8	5	22	8	Top			0	Doesn't
6	2	9	17	6	Loyal				

Рисунок 1.10. Использование таблицы сегментов клиентов

Можно визуализировать результаты сегментации клиентов с помощью сводной таблицы и вычислить сумму по колонке Сумма заказов в разрезе клиентских сегментов:

FreeBusta is knowledge
without borders!

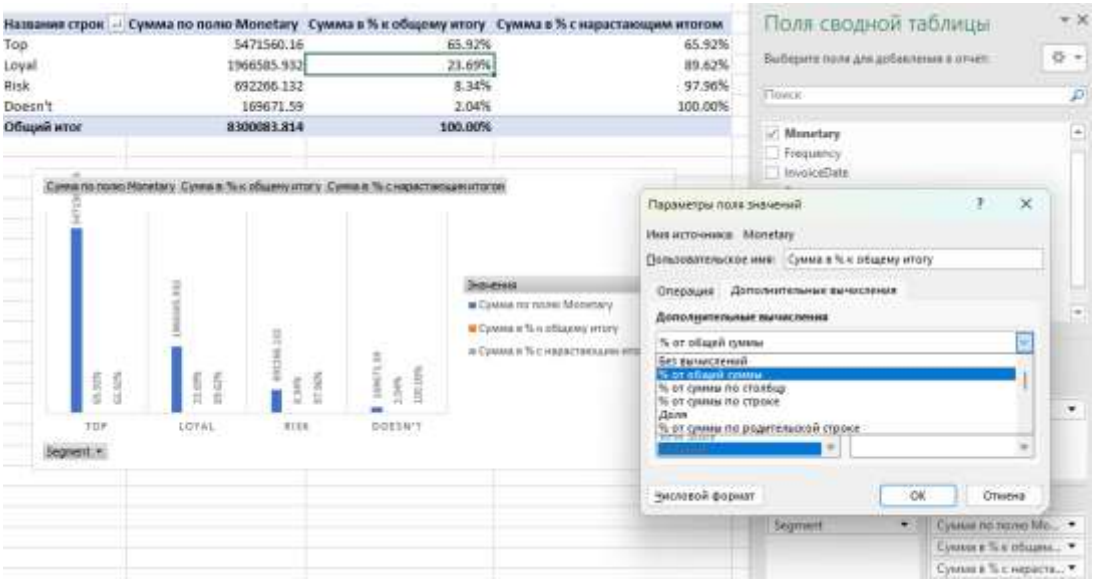


Рисунок 1.11. Построение результирующей сводной таблицы

Такой метод не пригодится, если:

1. Маленькая клиентская база, сегментация на множество групп невозможна.
2. Все клиенты слишком «свежие» для анализа.
3. Продукт не имеет повторных покупок и параметр «частота» бесполезен.
4. Один товар/услуга в продаже, невозможно повышать средний чек или развивать потребление.
5. Клиентская база статична.
6. Нет ресурсов или желания улучшать маркетинговую стратегию, анализ бесполезен.

Таким образом, подводя итоги, можно отметить, что:

1. RFM-анализ помогает поделить клиентов на сегменты, чтобы создать эффективную маркетинговую стратегию.
2. В процессе RFM-анализа всех клиентов делят на группы в зависимости от даты последней покупки, частоты покупок и размера чека.
3. Сделать такой анализ можно бесплатно с помощью таблиц в Excel, Google Sheets или специальных сервисов.
4. Чем масштабнее бизнес, тем чаще нужно проводить RFM-анализ.
5. Если у вас меньше 1000 клиентов, вы совсем молодой стартап или торгуете всего одним товаром — сегментировать аудиторию может быть бессмысленно.

FreeBusta is knowledge
without borders!

1.3. Simple ML для автоматизации процессов машинного обучения

Simple ML — это надстройка для Google Sheets, которая помогает сделать машинное обучение доступным для всех. Работает полностью в браузере благодаря TensorFlow.js. Это гарантирует, что данные остаются локальными и не покидают среду, что особенно важно для конфиденциальности.

Любой человек, даже не имеющий опыта программирования, может использовать Simple ML для экспериментов и применения некоторых возможностей машинного обучения к своим данным всего за несколько кликов, включая автоматическую обработку пропущенных значений, нормализацию данных и выбор подходящих гиперпараметров. Поскольку Simple ML поддерживает TensorFlow Decision Forests (TD-DF), можно импортировать обученные модели в экосистему TensorFlow.

1.3.1. Прогнозирование пропущенных значений

Процесс, который позволяет автоматически заполнять недостающие данные в таблице на основе анализа имеющихся данных, выполняется с использованием моделей машинного обучения, которые предсказывают наиболее вероятные значения для пропущенных ячеек. Рассмотрим основные этапы этого процесса:

1. Выбор столбца, в котором нужно заполнить недостающие данные (см. рис. 1.12).
2. Автоматическая предобработка данных (обработка категориальных признаков, нормализация числовых данных, игнорирование нерелевантных столбцов).
3. Выбор оптимального алгоритма (например, случайный лес или градиентный бустинг) для прогнозирования пропущенных значений. На основе имеющихся данных модель обучается предсказывать значения для выбранного столбца.
4. Платформа показывает, какие столбцы оказали наибольшее влияние на прогнозирование, что помогает понять логику работы модели (см. рис. 1.13).
5. Теперь, когда пропущенные значения заполнены, данные можно использовать для других задач анализа, таких как построение графиков, сводных таблиц или обучения новых моделей.

FreeBusta is knowledge
without borders!

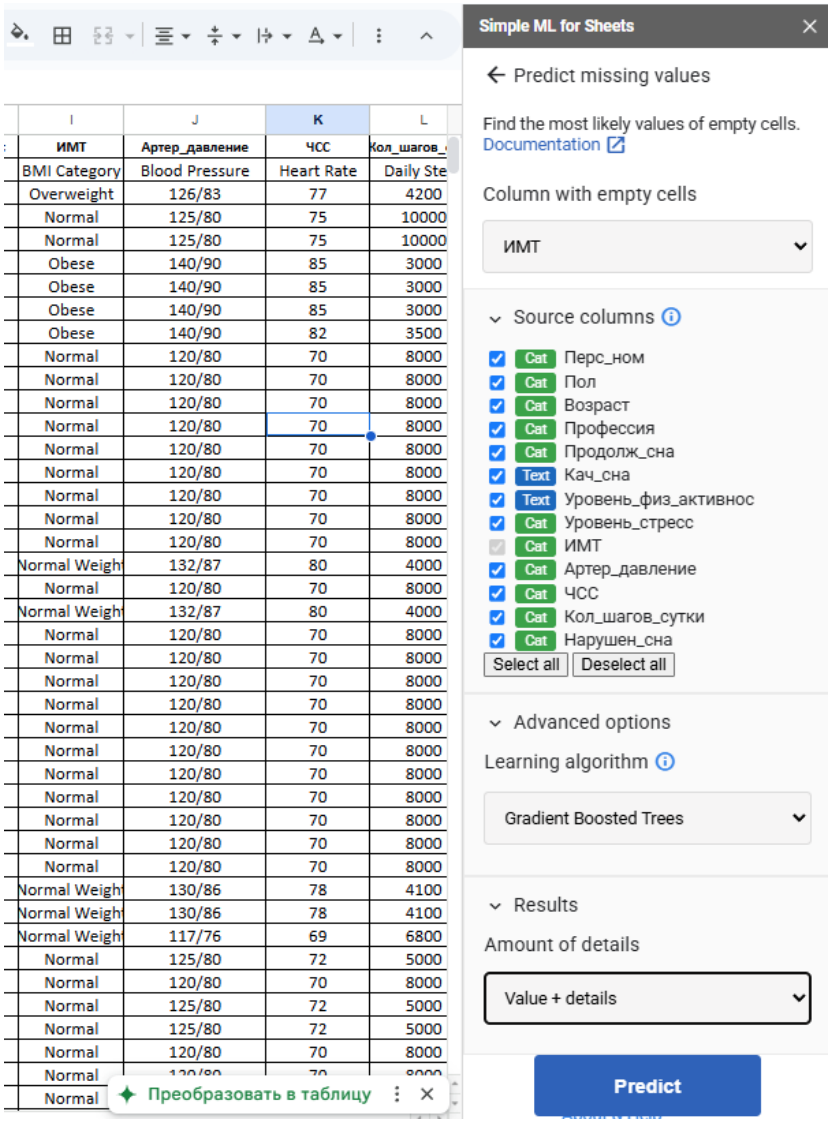


Рисунок 1.12. Настройка параметров для прогнозирования пропущенных значений

Предоставляет инструмент несколько видов результатов для заполнения пропусков: предсказанная категория(Predicted Category), вероятности для каждой категории (Class Probabilities), наиболее частая категория (Most frequent category), контекстное предсказание (Context-Based Prediction), интерполяция категорий (Category Interpolation), смешанный подход (Hybrid Approach).

Simple ML может выдавать вероятности принадлежности к каждой категории. Это позволяет оценить уверенность модели в своем прогнозе.

ИМТ	Артер_давление	ЧСС	Кол_шагов_сутки	Нарушен_сна	Pred:ИМТ	Pred:Normal	Pred:Overweight	Pred:Normal Weight	Pred:Obese	Pred:BMI Category
Normal	120/80	70	8000	None						
	120/80	70	8000	None	Normal	0.971165	0.00720524	0.00720944	0.00721133	0.00720914
	120/80	70	8000	None	Normal	0.971164	0.00720628	0.00720943	0.00721132	0.00720913
	120/80	70	8000	None	Normal	0.971165	0.00720524	0.00720944	0.00721133	0.00720914
Normal	120/80	70	8000	None						

Рисунок 1.13. Результат по пропущенным значениям

FreeBusta is knowledge without borders!

1.3.2. Выявление аномальных значений

Функция выявления аномальных значений в Simple ML позволяет автоматически обнаруживать выбросы или необычные данные в таблице. Это полезно для очистки данных, выявления ошибок или аномалий, которые могут исказить анализ.

В результате работы модели создаётся два столбца: Pred:Abnormality:Rings(«оценки аномалии» в диапазоне от 0 – больше нормальный до 1 – больше ненормальный) и Pred:Mostlikely:Rings (наиболее вероятные прогнозируемые значения для выбранного столбца).

ЧСС	Кол_шагов_сутки	Нарушен_сна	Pred:Abnormality:ЧСС	Pred:MostLikely:ЧСС
70	8000	None	0	70
68	7000	None	0.426508	70
72	5000	Insomnia	0	72
76	5500	None	0	76
76	5500	None	0	76
72	5000	None	0	72
72	5000	None	0	72

Рисунок 1.14. Результат по аномальным значениям

Изучается распределение данных в каждом столбце, далее модель обучается на основе имеющихся данных, чтобы понять, какие значения считаются «нормальными». Для числовых данных: модель ищет значения, которые сильно отклоняются от среднего или медианы. Для категориальных данных: модель выявляет редкие или неожиданные категории, которые встречаются значительно реже других. Для текстовых данных: модель может находить необычные или уникальные записи, которые не соответствуют общему паттерну.

1.3.3. Прогнозирование будущих значений

В этом случае модель машинного обучения использует исторические данные для предсказания будущих значений. Если данные представляют временной ряд, добавляется столбец с датами или временными метками.

После обучения модель экстраполирует тренды и предсказывает будущие значения на заданное количество шагов вперед. В результате получаем таблицу с прогнозируемыми значениями, графики для анализа трендов и изменений.

Задача прогнозирования предполагает сортировку значений по дате и выборку через регулярные промежутки времени, например каждый день, каждую неделю или каждый месяц. Требования к организации данных: первый столбец должен содержать даты, а следующие столбцы должны содержать одну или несколько серий значений; первая строка должна содержать название серии и при

FreeBusta is knowledge
without borders!

этом все серии должны иметь одинаковое количество значений/строк. В результате прогнозируются значения в любой строке, в которой есть дата, но нет значений. Далее можно построить графики и таблицы с прогнозируемыми значениями для интерпретации результатов.

После обучения модели Simple ML предоставляет отчеты с ключевыми метриками (например, точность, AUC, RMSE) и визуализацией важности признаков. Это помогает пользователям понять, какие данные оказали наибольшее влияние на результат, и принять обоснованные решения.

1.3.4. Обучение, оценка и интерпретация моделей

Как уже отмечалось ранее, Simple ML — это инструмент, который автоматизирует процесс машинного обучения, делая его доступным для пользователей без опыта программирования. Он позволяет выполнять ключевые этапы работы с моделями: обучение, оценку, интерпретацию и внедрение моделей.

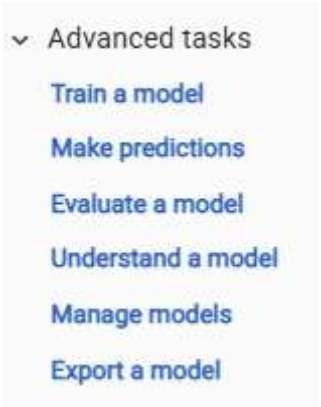


Рисунок 1.15. Результат по аномальным значениям

На рис. 1.15 показаны различные расширенные задачи, выполняемые при помощи Simple ML, а именно, обучение модели, выполнение прогнозов, оценка модели, понимание и управление моделью и экспорт модели в выбранную среду разработки.

На этапе обучения модели выбирается целевой столбец, а платформа обрабатывает данные, выбирает алгоритм и обучает модель за несколько кликов (см. рис. 1.16). После обучения модель может предсказывать новые значения для пропущенных или будущих значений.

FreeBusta is knowledge
without borders!

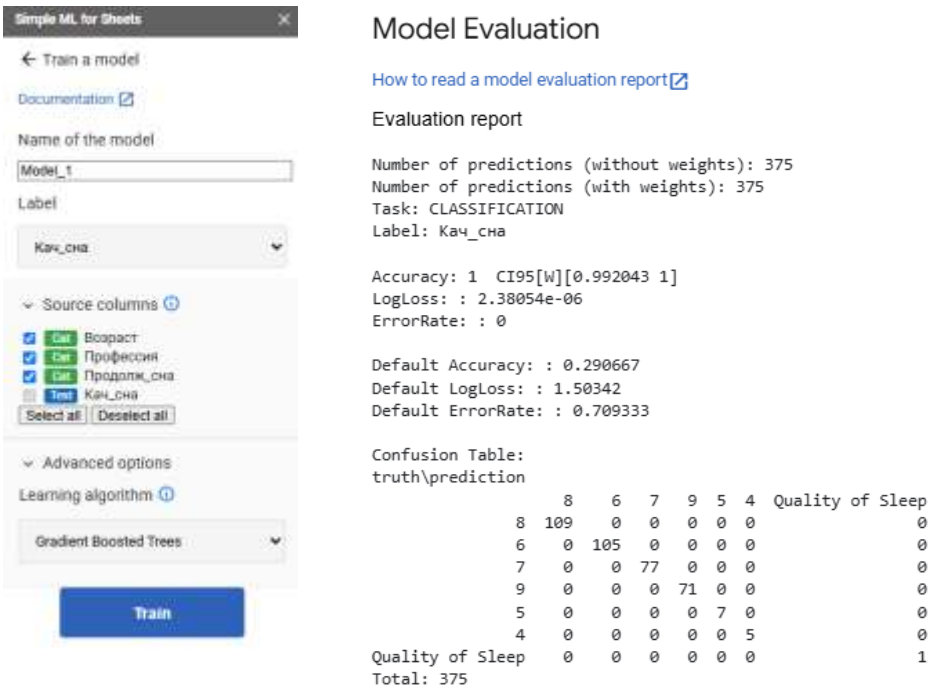


Рисунок 1.16. Результаты оценки обученной модели

Simple ML предоставляет метрики качества и графики для оценки эффективности модели. На рис. 1.17 приведены результаты этапа понимания модели, на котором платформа показывает важность признаков, помогая понять, какие данные более всего влияют на прогноз.

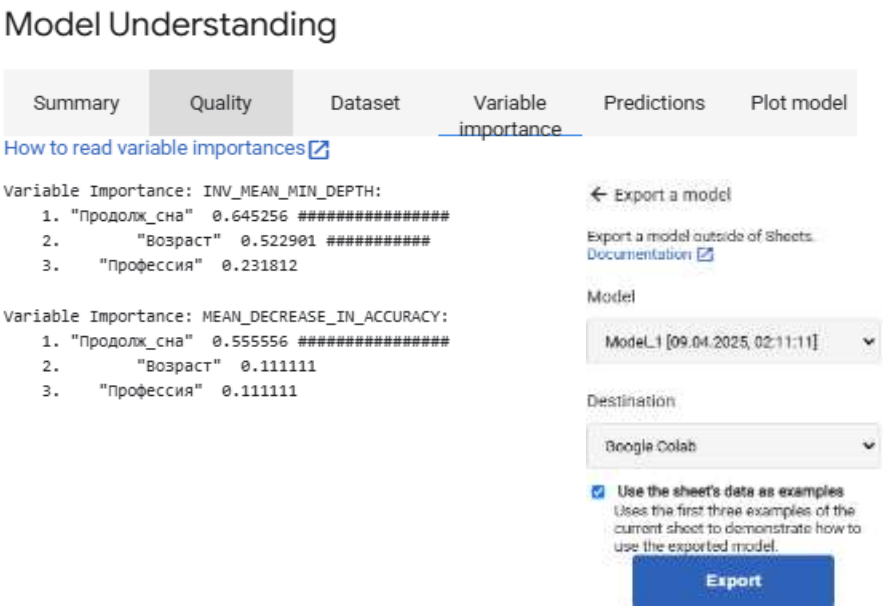


Рисунок 1.17. Этапы оценки качества обучения и экспорта модели

Далее можно сохранять, удалять или переключаться между разными моделями для разных задач. Можно также обученную модель, а также предсказанные

FreeBusta is knowledge
without borders!

результаты экспортировать в формат TensorFlow для использования в других проектах или интеграции с внешними системами.

1.4. Разведочный анализ с Mitosheet

Разведочный анализ данных (англ. exploratory data analysis, EDA) — анализ основных свойств данных, нахождение в них общих закономерностей, распределений и аномалий, построение начальных моделей, зачастую с использованием инструментов визуализации.

Понятие введено математиком Джоном Тьюки, который сформулировал цели такого анализа следующим образом:

— максимальное «проникновение» в данные;
— выявление основных структур;
— выбор наиболее важных переменных;
— обнаружение отклонений и аномалий;
— проверка основных гипотез;
— разработка начальных моделей.

Основные средства разведочного анализа — изучение вероятностных распределений переменных, построение и анализ корреляционных матриц, факторный анализ, дискриминантный анализ

Исследовательский анализ данных - самый важный и решающий шаг в науке о данных. Он не только предоставляет нам информацию о точках данных и функциях, но также помогает обнаруживать различные шаблоны данных, ассоциации, зависимости данных и др.

Существует большое количество библиотек Python, которые могут помочь в процессе EDA. MitoSheet является одной из них, инсталлируемой командой pip install mitosheet. Это библиотека с открытым исходным кодом, которая используется для создания интерактивных информационных панелей, где можно анализировать данные, визуализировать различные функции и соответствующим образом манипулировать данными.

Mito предоставляет пользовательский интерфейс, напоминающий электронные таблицы. Позволяет выполнять очистку, трансформацию и анализ данных без необходимости писать код вручную. Это позволяет быстро переключаться между анализом данных в Python и изучением/манипулированием данными в Mitosheet. Поскольку Mitosheet оптимизирован для анализа данных Python, каждая вкладка внутри Mitosheet представляет собой датафрейм Pandas. Mitosheet также может помочь легко импортировать csv- и xls-файлы в датафрейм одним нажатием кнопки, см. рис. 1.18.

FreeBusta is knowledge
without borders!

Рассмотрим, как мы можем использовать различные функции MitoSheet. Импортируем библиотеку:

```
import mitosheet
mitosheet.sheet(analysis_to_replay="id-thomfbxjls")
```

```
C:\Users\ARMUser\anaconda3\Lib\site-packages\pandas\core\arrays\masked.py:60: UserWarning: Pandas req
uires version '1.3.6' or newer of 'bottleneck' (version '1.3.5' currently installed).
  from pandas.core import (
```

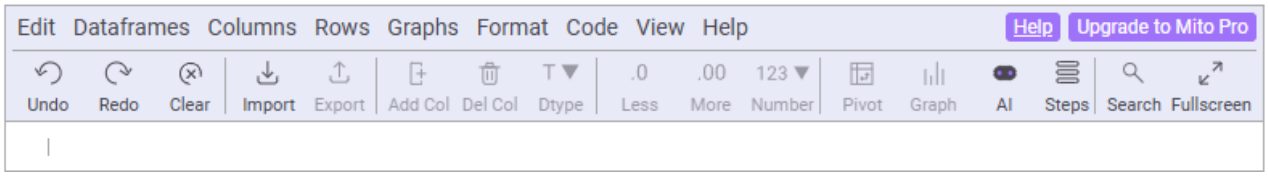


Рисунок 1.18. Рабочая область библиотеки Mitosheet

Для начала работы с данными их нужно загрузить в Mito. Поддерживаются различные форматы: csv, xls, json, sql. Как только появится кадр данных, отображаемый в Mitosheet, можно сразу же начать исследовать данные: просматривать данные в виде таблицы, проверять типы данных для каждого столбца, оценивать количество строк и столбцов, анализировать пропущенные значения (NaN).

Для каждого изменения, внесенного в Mito, автоматически генерируется соответствующий код на Python, который можно запустить для применения этих изменений к исходным фреймам данных, поскольку по умолчанию все операции выполняются на копии фрейма данных и только после выполнения сгенерированного кода изменения фиксируются в основных данных.

Очистка данных — это ключевой этап подготовки данных для анализа. Mito предоставляет для этого множество инструментов, рассмотрим их далее.

Удаление дубликатов

1. Идентификация дубликатов. Функция дедупликации проверяет строки в таблице на наличие полных или частичных совпадений. Можно указать, какие столбцы следует учитывать при поиске дубликатов. Например, если нужно удалить строки, где значения в определённых столбцах совпадают, а остальные столбцы игнорируются.

FreeBusta is knowledge without borders!

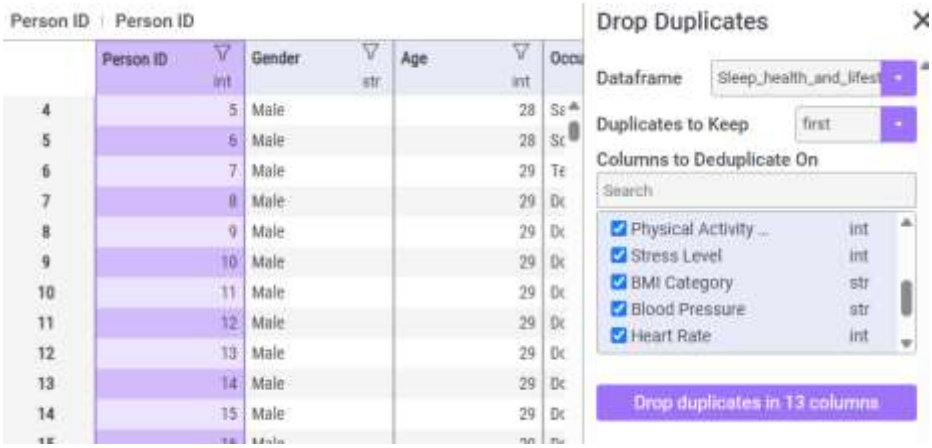


Рисунок 1.19. Функциональная панель удаления дубликатов

2. Удаление дубликатов. После идентификации дубликатов функция оставляет только одну копию каждой строки и удаляет остальные.
3. Гибкость настройки. Можно настроить то, какие строки считать дубликатами, сохранять ли первую или последнюю встречную строку среди дубликатов.
4. Автоматическая генерация кода. Одной из ключевых особенностей Mito является автоматическая генерация Python-кода для всех выполненных операций. Это позволяет вам воспроизводить процесс дедупликации в будущем или применять его к другим наборам данных.

Обработка пропущенных значений

1. Удаляем строки или столбцы с пропущенными значениями.
2. Заполняем пропущенные значения константой, средним, медианой или другим значением.

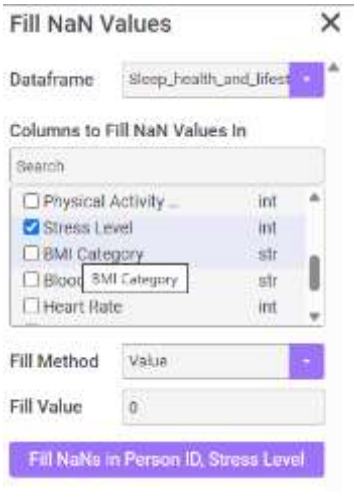


Рисунок 1.20. Функциональная панель обработки пропущенных значений

FreeBusta is knowledge without borders!

Разделение/ объединение, создание вычисляемых столбцов, изменение типов данных

Mito поддерживает разделение столбца на несколько колонок.

К функции объединения можно получить доступ через панель задач слияния, а затем выбрать тип слияния «уникальный слева» или «уникальный справа».

— *уникальный слева:* включает каждую строку из первого листа, которая не совпадает со вторым листом;

— *уникальный справа:* включает каждую строку со второго листа, которая не имеет совпадений на первом листе.

Как и другие типы слияний, Mito использует ключ слияния, который вы выбираете для каждого листа, для обнаружения совпадений.

Функцию слияния Mito можно использовать для объединения наборов данных по горизонтали. Слияние ищет совпадения между ключевым столбцом первого листа и ключевым столбцом второго листа. Mito поддерживает все наиболее распространенные слияния:

— left merge: включает все строки с первого листа и только совпадающие строки со второго листа.

— right merge: включает все строки со второго листа и только совпадающие строки с первого листа.

— inner merge: включает только те строки, которые совпадают на обоих листах.

— outher merge: включает все строки с обоих листов, независимо от того, есть ли совпадения на другом листе.

— lookup merge (слияние поиска): левое соединение, но включает только первое совпадение со второго листа, если их несколько.

Можно также изменить тип данных для столбца (например, преобразовать текст в числа или даты).

Mito позволяет создавать новые столбцы на основе существующих данных: использовать математические операции, условные выражения, извлекать части данных, например, год из даты:

FreeBusta is knowledge
without borders!

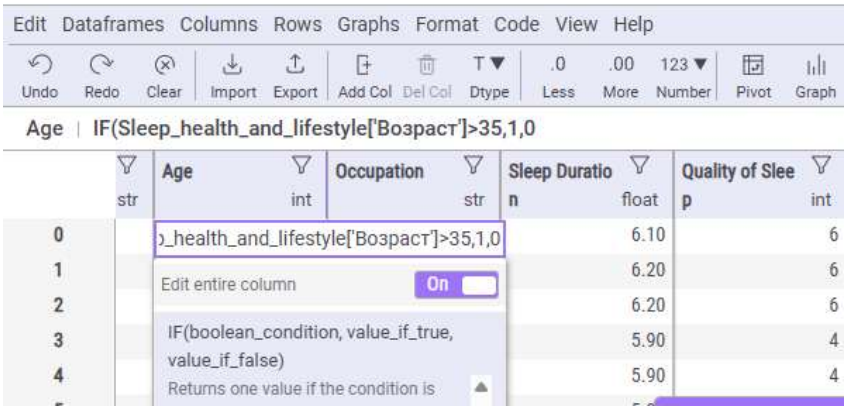


Рисунок 1.21. Добавление вычисляемой колонки

Фильтрация данных

Mito обеспечивает мощную фильтрацию за счет комбинации фильтров и групп фильтров. Фильтры — это условие, которое оценивается как истинное или ложное для каждой ячейки в столбце, либо совокупность фильтров, объединенных оператором И/ИЛИ. Фильтры Mito являются динамичными, то есть в наборе данных останутся только те ячейки, для которых выполнены условия фильтра.

Создание сводной таблицы

Чтобы создать сводную таблицу, выберем "Pivot Table" и настроим параметры сводной таблицы: rows - признаки, которые будут использоваться для группировки строк; columns - признаки, которые будут использоваться для группировки столбцов; values - признак, по которому будут выполняться агрегатные операции; aggregation - тип агрегации (например, сумма, среднее значение, количество, максимум, минимум).

```
# Pivoted Sleep_health_and_lifestyle into SHL_pivot
tmp_df = Sleep_health_and_lifestyle[['Occupation', 'Physical Activity Level', 'Stress Level']].copy()
pivot_table = tmp_df.pivot_table(
    index=['Occupation'],
    columns=['Physical Activity Level'],
    values=['Stress Level'],
    aggfunc={'Stress Level': ['mean']}
)
pivot_table = pivot_table.set_axis([flatten_column_header(col) for col in pivot_table.keys()], axis=1)
SHL_pivot = pivot_table.reset_index()
```

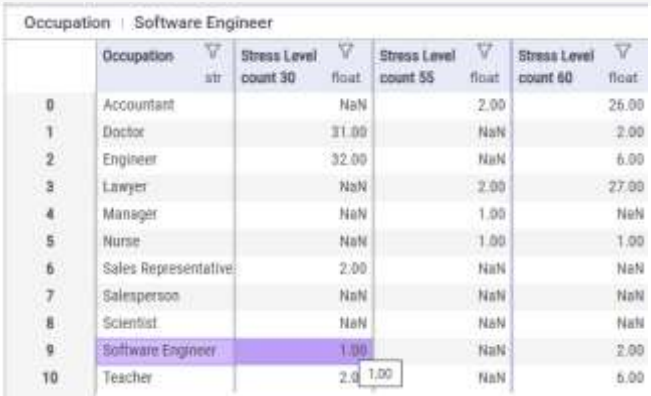


Рисунок 1.22. Создание сводной таблицы в Mito

FreeBusta is knowledge without borders!

Графики

Графики в Mito предназначены для того, чтобы помочь получить интуитивное представление о данных и создать готовые к презентации графики для обмена идеями. Mito создает интерактивные и настраиваемые графики, используя графическую библиотеку с открытым исходным кодом Plotly Express.

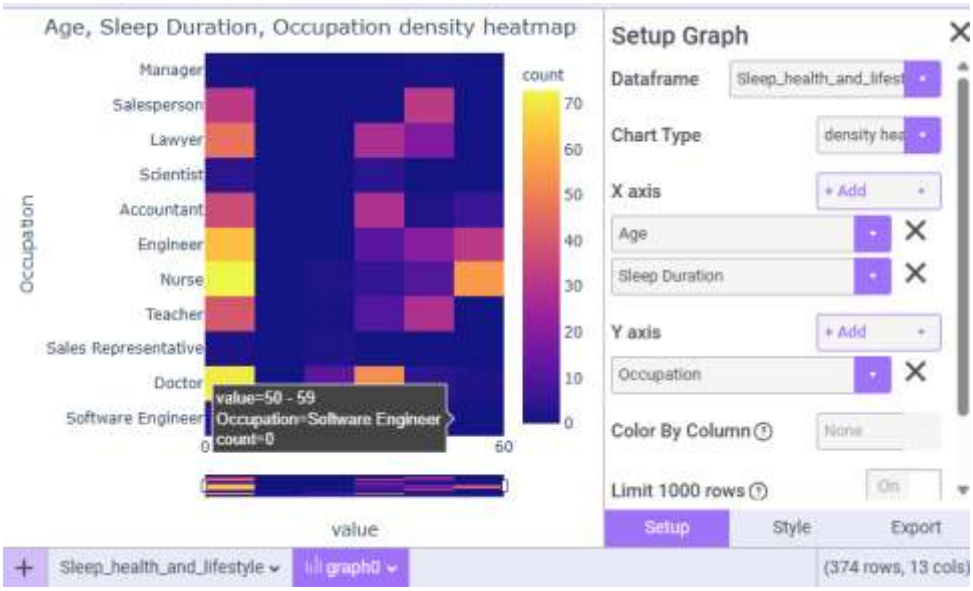


Рисунок 1.23. Создание графика в Mito

Для настройки параметров графика устанавливаем:

— *data source*: лист, содержащий данные, которые вы хотите отобразить в виде графика;

— *тип диаграммы*: тип создаваемой диаграммы. Mito поддерживает: scatter plots, line charts, bar charts, histograms, box plots, violin plots, strip plots, density heatmaps, density countour maps;

— *ось X*: данные для построения графика по оси X. Можно выбрать несколько рядов либо вдоль оси x, либо по оси y, если ряды имеют схожие dtypes;

— *ось Y*: данные для построения графика по оси Y с аналогичным условием;

— *color by column*: дополнительный столбец для дальнейшей разбивки графических данных с использованием атрибута цвета;

— *filter to safe size*: по умолчанию Mito отображает только первые 1000 строк данных, чтобы гарантировать, что вкладка браузера не выйдет из строя при попытке загрузить слишком много данных в график. Отключение фильтра для сохранения размера графов всего фрейма данных может замедлить или привести к сбою вкладки браузера.

FreeBusta is knowledge without borders!

Экспорт в csv и xls

Экспорт данных в форматы csv и xls — это одна из ключевых функций Mito, которая позволяет сохранить результаты анализа или обработки данных для дальнейшего использования. Mito предоставляет простой и интуитивно понятный интерфейс для экспорта данных с настройкой формата представления (например, разные листы для таблиц), кодировки (например, utf-8 для кириллицы), разделителей (‘,’, ‘;’) и других параметров, а также автоматически генерирует соответствующий python-код для воспроизведения процесса.

Чтобы использовать измененные кадры данных в остальной части вашего анализа, запустите код, который генерирует Mito, щелкнув ячейку, содержащую код, и нажмите кнопку воспроизведения на панели инструментов Jupyter.

FreeBusta is knowledge
without borders!



2. ОКОННЫЕ ФУНКЦИИ И МНОГОМЕРНАЯ АГРЕГАЦИЯ

2.1. Язык запросов для извлечения и обработки данных

На начальном этапе знакомства с анализом данных мы рассматривали базовые инструменты. Эти инструменты идеально подходят для работы с небольшими датасетами и позволяют быстро выполнять простые операции: фильтрацию, группировку, расчет агрегатов и построение сводных таблиц. Однако, когда объем данных увеличивается, эти инструменты начинают сталкиваться с ограничениями, такими как нехватка оперативной памяти, снижение производительности и сложность масштабирования.

Вот здесь на первый план выходит SQL — мощный язык запросов, который позволяет работать напрямую с данными, хранящимися в базах данных. Благодаря своей оптимизации и способности обрабатывать большие объемы информации, SQL становится незаменимым инструментом для анализа данных в реальных условиях. В частности, SQL предоставляет уникальные возможности для выполнения сложных аналитических задач, таких как оконные функции и многомерная агрегация, которые часто сложнее эффективно реализовать альтернативным образом.

Sql – неотъемлемая часть аналитического процесса, обеспечивающая преобразование сырых данных в структурированную информацию для принятия решений. Благодаря своей универсальности, эффективности и интеграции с аналитическими платформами является одним из основных языком запросов в анализе данных. Преимущества применения SQL в анализе данных в том, что SQL работает напрямую с базой данных, минимизируя передачу данных на клиентскую сторону, есть возможность использования индексов и оптимизации запросов, а также в том, что базовые инструменты могут быть ограничены объемом оперативной памяти, в то время как SQL может обрабатывать терабайты данных.

Одним из ключевых преимуществ SQL является поддержка оконных функций, которые позволяют выполнять вычисления над "окном" данных без потери исходных строк. Это особенно полезно, когда необходимо провести детальный анализ данных, сохранив при этом контекст каждой записи. Например, с помощью оконных функций можно рассчитать ранг, накопленную сумму или разницу между текущей и предыдущей записью.

В отличие от традиционной агрегации (например, group by), которая сворачивает данные до уровня групп, оконные функции сохраняют все строки, что делает их идеальными для задач, требующих детализации. Например, с помощью

FreeBusta is knowledge
without borders!

оконных функций можно легко определить, какое место занимает каждый клиент в рейтинге по сумме покупок, или рассчитать скользящее среднее для временных рядов.

Оконная функция (см. рис. 2.1) применяется к набору строк, спецификация «окна» задаётся в SQL при помощи инструкции OVER. Стандарт SQL поддерживает несколько типов оконных функций: агрегатные, ранжирующие, аналитические (функции распределения) и функции смещения. *Агрегатные оконные функции* (aggregate window functions) — это те же агрегатные функции, применяемые в контексте оконных запросов, а не только в группировках. Эти функции работают с наборами данных, определенными либо спецификациями окна, либо запросами с группировками. К *ранжирующим функциям* (ranking functions) относятся следующие: rank, dense_rank. Таким образом, оконные функции предоставляют гибкие возможности для анализа данных, позволяя выполнять сложные вычисления над "окном" данных без потери исходной детализации. *Аналитические функции* (или статистические функции) выполняют вычисления, связанные с распределением данных, такие как процентиль, медиана или квантиль. *Функции смещения* (lead, lag) позволяют получить доступ к значениям соседних строк в окне.

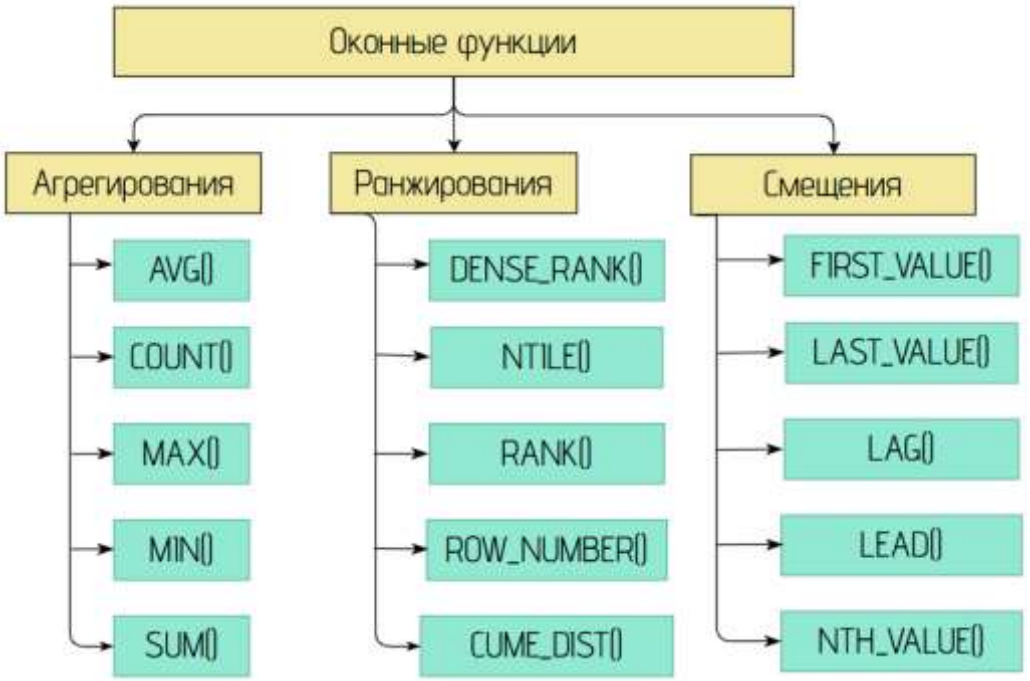


Рисунок 2.1. Виды оконных функций

Есть и ограничения при работе с оконными функциями: закономерно может снижаться производительность при работе с очень большими окнами или плохо оптимизированными запросами, и также необходимо четко понимать логику оконной функции, чтобы избежать ошибок в расчетах.

FreeBusta is knowledge
without borders!

Оконные функции в SQL используют инструкцию OVER, которая позволяет задать параметры обработки данных. В ней можно выделить следующие компоненты: группировка (PARTITION BY) — разделение данных на подмножества, внутри которых выполняются вычисления. Каждая группа обрабатывается независимо от других; сортировка (ORDER BY) — упорядочивание строк внутри каждой группы для определения последовательности выполнения операций; рамки окна (FRAME) — указание диапазона строк, которые будут использоваться для расчетов. Например, это может быть фиксированное количество предыдущих или следующих строк.



Рисунок 2.2. Компоненты оконной функции

Оконные функции можно рассматривать как комбинацию группировки и последовательной обработки данных. С одной стороны, они позволяют разделять данные на группы с помощью PARTITION BY, обеспечивая независимую обработку каждой группы. С другой стороны, за счет ORDER BY и специальных рамок окна (ROWS/RANGE/GROUPS), они дают возможность анализировать данные в заданном порядке, "заглядывать" в соседние строки или накапливать результаты по мере прохождения через набор записей.

Таким образом, переход от базовых инструментов к SQL позволяет расширить аналитические возможности за счет использования оконных функций, которые обеспечивают более глубокий и гибкий анализ данных.

2.2. Агрегация со скользящим окном

Скользящее окно (или движущееся окно) — это механизм в SQL, позволяющий выполнять вычисления над подмножеством строк, которые «движутся» по данным. Это особенно полезно для анализа временных рядов или последовательностей. Агрегация со скользящим окном реализуется с помощью оконных функций, таких как SUM, AVG, MIN, MAX и других, совместно с инструкцией OVER.

FreeBusta is knowledge
without borders!

В отличие от обычной группировки (GROUP BY), оконные функции сохраняют доступными исходные строки данных.

Размер и положение окна можно настраивать: ROWS BETWEEN UNBOUNDED PRECEDING AND CURRENT ROW — накопительная агрегация (кумулятивное окно), ROWS BETWEEN 3 PRECEDING AND 1 FOLLOWING — окно, включающее три предыдущие и одну следующую строку относительно текущей. Скользящее окно часто используется для анализа временных рядов, например, расчет скользящей средней (moving average), определение трендов и сезонности, обнаружение аномалий или изменений в данных.

Элемент секционирования (PARTITION BY) позволяет разбить исходный набор данных на подмножества (секции), где значения атрибутов, указанных для секционирования, совпадают с соответствующими значениями в текущей строке. Этот процесс часто воспринимается как аналог группировки или коррелирующих подзапросов, но на самом деле он имеет свои особенности.

Отличие от группировки. В отличие от оператора GROUP BY, который сворачивает данные до уровня групп, секционирование сохраняет все строки исходного набора. Оно просто определяет логические группы внутри которых выполняются вычисления, не изменяя структуру данных.

Отличие от коррелирующих подзапросов. Секционирование работает на основе виртуальной таблицы, которая формируется на этапе выполнения запроса SELECT. Это означает, что фильтры из внешнего запроса уже применены к данным перед тем, как секционирование начинает свою работу. В то время как коррелирующие подзапросы требуют повторного применения всех фильтров для каждой строки, секционирование использует уже отфильтрованный набор данных.

Не все функции требуют указания всех трёх элементов. Некоторые работают только с группировкой или сортировкой, без необходимости явно задавать границы окна. В отличие от группировки, которая разбивает всю выборку на непересекающиеся группы по общему для всех правилу, оконные функции позволяют каждой функции оперировать своими собственными критериями сегментирования данных.

Приведём пример (см. табл. 2.1) рекурсивного запроса, который демонстрирует работу с оконными функциями или рекурсией для вычисления накопительной суммы.

Более того, даже при наличии глобально заданного «окна» в запросе, они могут динамически адаптировать его параметры под свои нужды, как показано на рис. 2.3.

FreeBusta is knowledge
without borders!



Таблица 2.1. Альтернативные вычисления накопительной суммы

Рекурсия для вычисления накопительной суммы	*Реализация с помощью оконных функций, используя SUM() с агрегацией по окну*

`WITH RECURSIVE cumulative_sum(value, total) AS (`
`  SELECT 1 AS value, 1 AS total`
`  UNION ALL`
`  SELECT`
`  value + 1,`
`  total + (value + 1)`
`  FROM cumulative_sum`
`  WHERE value < 10`
`)`
`table cumulative_sum;`
	`SELECT value,`
	`  SUM(value)`
	`  OVER (ORDER BY value`
	`  ROWS BETWEEN UNBOUNDED PRECEDING AND CURRENT ROW) AS total`
	`FROM generate_series(1, 10) AS value;`

```
SELECT
    i,
    row_number() OVER w r,
    sum(i) OVER (w
        ROWS BETWEEN 1 PRECEDING
        AND 1 FOLLOWING -- скользящее окно
        EXCLUDE CURRENT ROW)
FROM generate_series(0, 9) i
WINDOW w AS (PARTITION BY i / 5 ORDER BY i);
```

	i integer	r bigint	sum bigint
1	0	1	1
2	1	2	2
3	2	3	4
4	3	4	6
5	4	5	3
6	5	1	6
7	6	2	12
8	7	3	14
9	8	4	16
10	9	5	8

Рисунок 2.3. Запрос с разными критериями сегментирования

Окно определено как w, и его параметры задаются следующим образом:

— PARTITION BY i / 5: Разбивает данные на группы (сегменты), где каждая группа формируется на основе целочисленного деления i на 5. Это означает, что все значения i, которые дают одинаковый результат при целочисленном делении на 5, попадают в одну группу.

— ORDER BY i: Упорядочивает строки внутри каждой группы по возрастанию значения i.

Для каждой строки будет рассчитана сумма i-значений из предыдущей и следующей строк, но без учета текущей строки. Скользящее окно (ROWS BETWEEN 1 PRECEDING AND 1 FOLLOWING) позволяет выполнять агрегации над соседними строками, что особенно полезно для анализа временных рядов или других последовательностей данных.

Многомерный анализ предполагает разбиение данных по нескольким измерениям (в данном случае: профессия, уровень физической активности и возраст) и вычисление агрегированных метрик для каждого сочетания этих измерений.

FreeBusta is knowledge
without borders!

Мы будем использовать оконные функции для анализа данных без их сворачивания в группы.

```
SELECT occupation, gender, physical_activity_level, age,
    ROUND(AVG(stress_level) OVER (agr_func), 2) AS avg_stress,
    SUM(stress_level) OVER (agr_func) AS total_stress,
    MIN(stress_level) OVER (agr_func) AS min_stress,
    MAX(stress_level) OVER (agr_func) AS max_stress,
    COUNT(*) OVER (agr_func) AS record_count
FROM shl
WINDOW agr_func as (PARTITION BY occupation, physical_activity_level, age ORDER BY gender);
```

Data Output

	occupation character varying	gender character vary	physical_acti integer	age integer	avg_stress numeric	total_stress bigint	min_stress integer	max_stress integer	record_count bigint
37	Accountant	Female	80	39	3.00	6	3	3	2
38	Doctor	Male	30	29	8.00	48	8	8	6
39	Doctor	Male	30	29	8.00	48	8	8	6
40	Doctor	Male	30	29	8.00	48	8	8	6
41	Doctor	Male	30	29	8.00	48	8	8	6
42	Doctor	Male	30	29	8.00	48	8	8	6
43	Doctor	Male	30	29	8.00	48	8	8	6
44	Doctor	Male	30	31	8.00	24	8	8	3
45	Doctor	Male	30	31	8.00	24	8	8	3
46	Doctor	Male	30	31	8.00	24	8	8	3

Рисунок 2.4. Многомерный анализ уровня стресса с разбивкой по критериям

Если для стандартных агрегатных функций сортировка является необязательным дополнением, то для некоторых специальных функций определение порядка данных критически важно и задается через конструкцию WITHIN GROUP (ORDER BY ...).

```
SELECT occupation, PERCENTILE_CONT(0.5)
WITHIN GROUP (ORDER BY stress_level) AS median_stress,
 MODE() WITHIN GROUP (ORDER BY stress_level) AS mode_stress
FROM shl GROUP BY occupation;
```

Data Output

	occupation character varying (30)	median_stress double precision	mode_stress integer
1	Accountant	4	4
2	Doctor	6	8
3	Engineer	3	3
4	Lawyer	5	5
5	Manager	5	5
6	Nurse	6	8
7	Sales Representative	8	8
8	Salesperson	7	7
9	Scientist	7	6
10	Software Engineer	5	5
11	Teacher	4	4

Рисунок 2.5. Общий пример вывода агрегирующих функций

На данный момент PostgreSQL предоставляет три таких функции, требующих *явного указания порядка сортировки*: mode (), percentile_cont (),

FreeBusta is knowledge
without borders!

percentile_disc(), вычисляющие, соответственно, моду в наборе данных, процентиль на основе непрерывного и дискретного распределения значений.

И также *гипотезирующие функции*, или функции ранжирования: rank(), dense_rank(), percent_rank(), cume_dinst(), присваивающие ранг каждой строке в зависимости от порядка сортировки, ранг без пропусков, вычисляющие относительный ранг строки в виде процентного отношения: (ранг строки - 1) / (общее количество строк - 1), кумулятивную дистрибуцию (накопленное распределение) значения в наборе данных, показывающую долю строк со значением меньше или равным текущему: (количество строк ≤ текущей) / (общее количество строк), соответственно.

В запросе, показанном на рис. 2.5, PERCENTILE_CONT(0.5) вычисляет медиану (50-й процентиль) уровня стресса, используя WITHIN GROUP (ORDER BY stress_level) для упорядочивания данных перед расчетом. MODE() определяет наиболее часто встречающееся значение (моду) уровня стресса. И здесь также требуется WITHIN GROUP (ORDER BY stress_level) для корректной работы. Данные сгруппированы по профессии, чтобы вычисления выполнялись для каждой группы отдельно.

Результат этих функций представляет собой значение, которое вернула бы соответствующая оконная функция для «гипотетической» строки. Эта строка формируется из переданных аргументов так, как если бы её включили в отсортированный набор строк, созданный на основе сортирующих аргументов. При этом количество и типы элементов в списке аргументов функции должны точно совпадать со списком, используемым для сортировки.

2.3. Ранжирование и смещение в группах данных

Ранжирующие функции позволяют присваивать ранги или оценивать относительное положение строк в наборе данных. В данном случае мы применим эти функции к таблице shl для анализа уровня стресса с разбивкой по профессии и уровню физической активности.

FreeBusta is knowledge
without borders!



```
SELECT occupation,physical_activity_level,stress_level,
    RANK() OVER (rang_func) AS rank_stress,
    DENSE_RANK() OVER (rang_func) AS dense_rank_stress,
    PERCENT_RANK() OVER (rang_func) AS percent_rank_stress,
    CUME_DIST() OVER (rang_func) AS cume_dist_stress
FROM shl
WINDOW rang_func as (PARTITION BY occupation ORDER BY stress_level DESC);
```

Data Output

	occupation character varyir	physical_activ integer	stress_level integer	rank_stress bigint	dense_rank_stress bigint	percent_rank_stress double precision	cume_dist_stress double precision
5	Accountant	45	7	1	1	0	0.16216216216216217
6	Accountant	45	7	1	1	0	0.16216216216216217
7	Accountant	50	6	7	2	0.16666666666666666	0.24324324324324326
8	Accountant	55	6	7	2	0.16666666666666666	0.24324324324324326
9	Accountant	55	6	7	2	0.16666666666666666	0.24324324324324326
10	Accountant	60	4	10	3	0.25	0.9459459459459459
11	Accountant	60	4	10	3	0.25	0.9459459459459459
12	Accountant	60	4	10	3	0.25	0.9459459459459459
13	Accountant	60	4	10	3	0.25	0.9459459459459459

Рисунок 2.6. Общий пример вывода функций ранжирования

Запрос разделяет данные на группы по профессии, чтобы ранжирование выполнялось внутри каждой профессии; сортирует строки внутри каждой группы по убыванию уровня стресса; присваивает ранг, начиная с 1, и ,если значения совпадают, следующий ранг пропускается; затем присваивает ранг без пропусков и даже если значения совпадают, следующий ранг не пропускается; вычисляет относительный ранг в виде процентного отношения: (ранг строки - 1) / (общее количество строк - 1); вычисляет кумулятивную дистрибуцию: (количество строк ≤ текущей) / (общее количество строк).

Функции смещения (*window offset functions*) — это специальные оконные функции в SQL, которые позволяют обращаться к значениям из других строк в рамках окна данных. Они полезны для анализа временных рядов, сравнения текущих значений с предыдущими или последующими, а также для вычисления разностей между соседними строками.

Например, если нужно проанализировать изменение продаж по дням, для чего пишем запрос, возвращающий значение sales из предыдущей строки и из следующей строки (по дате), значение sales (по дате), и далее, вычисляет разницу между текущим значением и предыдущим значением. При этом происходит разделение данных по продукту, чтобы анализ выполнялся отдельно для каждого продукта, и строки упорядочиваются внутри каждой группы по дате

FreeBusta is knowledge
without borders!

```
SELECT order_date, product_name, sales,
    LAG(sales, 1) OVER (offset_func) AS prev_day_sales,
    LEAD(sales, 1) OVER (offset_func) AS next_day_sales,
    sales - LAG(sales, 1) OVER (offset_func) AS sales_diff
FROM orders
WINDOW offset_func as (PARTITION BY product_name ORDER BY order_date);
```

Data Output

	order_date date	product_name character varying (300)	sales double precision	prev_day_sales double precision	next_day_sales double precision	sales_diff double precision
77	2019-11-28	24 Capacity Maxi Data ...	1263.3	505.32	1347.52	757.98
78	2020-06-10	24 Capacity Maxi Data ...	1347.52	1263.3	421.1	84.22000000000003
79	2020-09-04	24 Capacity Maxi Data ...	421.1	1347.52	[null]	-926.42
80	2017-01-13	3-ring staple pack	5.64	[null]	7.52	[null]
81	2018-06-07	3-ring staple pack	7.52	5.64	5.64	1.88
82	2018-08-13	3-ring staple pack	5.64	7.52	3.76	-1.88
83	2018-12-14	3-ring staple pack	3.76	5.64	10.528	-1.88
84	2019-09-23	3-ring staple pack	10.528	3.76	9.024	6.768000000000001
85	2020-12-02	3-ring staple pack	9.024	10.528	[null]	-1.5040000000000013
86	2017-03-03	3.6 Cubic Foot Counter ...	176.772	[null]	58.924	[null]
87	2019-08-13	3.6 Cubic Foot Counter ...	58.924	176.772	1473.1	-117.84799999999998

Рисунок 2.7. Общий пример вывода функций смещения

Чтобы найти первое и последнее значения в окне, выполняем следующую команду:

```
SELECT order_date, product_name, sales,
    FIRST_VALUE(sales) OVER (PARTITION BY product_name ORDER BY order_date) AS
    LAST_VALUE(sales) OVER (PARTITION BY product_name ORDER BY order_date
    ROWS BETWEEN UNBOUNDED PRECEDING AND UNBOUNDED FOLLOWING) AS last_sale
FROM orders;
```

Data Output

	order_date date	product_name character varying (300)	sales double precision	first_sale double precision	last_sale double precision
21	2020-11-12	#10- 4 1/8" x 9 1/2" Secur...	12.224	15.28	12.224
22	2018-12-27	#10-4 1/8" x 9 1/2" Premi...	113.328	113.328	62.96
23	2020-04-30	#10-4 1/8" x 9 1/2" Premi...	62.96	113.328	62.96
24	2018-11-03	#10 Gummed Flap White ...	6.608	6.608	9.912
25	2019-01-15	#10 Gummed Flap White ...	16.52	6.608	9.912
26	2019-04-08	#10 Gummed Flap White ...	8.26	6.608	9.912
27	2020-10-31	#10 Gummed Flap White ...	9.912	6.608	9.912
28	2019-04-08	#10 Self-Seal White Envel...	8.872	8.872	22.18
29	2019-09-11	#10 Self-Seal White Envel...	11.09	8.872	22.18
30	2019-10-15	#10 Self-Seal White Envel...	66.54	8.872	22.18
31	2020-09-11	#10 Self-Seal White Envel...	22.18	8.872	22.18
32	2017-09-21	#10 White Business Envel...	78.35	78.35	37.608
33	2017-11-16	#10 White Business Envel...	78.35	78.35	37.608

Рисунок 2.8. Просмотр первого и последнего значения в окне

Приведём ещё пример запроса для построения рейтинга профессий на основе уровня стресса и индекса массы тела.

FreeBusta is knowledge
without borders!

Запрос для каждой группы профессий отдельно вычисляет средний уровень стресса для каждой профессии, присваивает ранг профессиям на основе среднего уровня стресса. Профессия с самым высоким уровнем стресса получает ранг 1. Затем вычисляет средний индекс массы тела для каждой профессии и присваивает ранг профессиям на основе среднего BMI. Профессия с самым высоким BMI получает ранг 1.

```
SELECT occupation,avg_stress,stress_rank,avg_bmi,bmi_rank,
    (stress_rank + bmi_rank) AS total_rank
FROM
(WITH B AS (SELECT  occupation, stress_level, bmi_category,
        CASE
            WHEN bmi_category = 'Normal Weight' THEN 1
            WHEN bmi_category = 'Normal' THEN 2
            WHEN bmi_category = 'Overweight' THEN 3
            WHEN bmi_category = 'Obese' THEN 4
            ELSE NULL
        END AS bmi_code
    FROM shl
)
SELECT occupation, AVG(stress_level) AS avg_stress,
    RANK() OVER (ORDER BY AVG(stress_level) DESC) AS stress_rank,
    AVG(bmi_code) AS avg_bmi,
    RANK() OVER (ORDER BY AVG(bmi_code) DESC) AS bmi_rank
FROM B
GROUP BY occupation) subquery
ORDER BY total_rank;
```

Data Output

	occupation character varying (30)	avg_stress numeric	stress_rank bigint	avg_bmi numeric	bmi_rank bigint	total_rank bigint
1	Sales Representative	8.000000000	1	4.000000000	1	2
2	Scientist	7.000000000	2	3.000000000	2	4
3	Salesperson	7.000000000	2	3.000000000	2	4
4	Manager	5.000000000	8	3.000000000	2	10
5	Nurse	5.547945205	6	2.808219178	6	12
6	Software Engineer	5.800000000	5	2.200000000	7	12
7	Doctor	6.732394366	4	2.084507042	9	13
8	Lawyer	5.063829787	7	2.106382978	8	15
9	Teacher	4.525000000	10	2.875000000	5	15
10	Accountant	4.594594594	9	2.027027027	10	19
11	Engineer	3.888888888	11	1.984126984	11	22

Messages

```
Successfully run. To
query runtime: 71 ms
11 rows affected.
```

Рисунок 2.9. Построение рейтинга профессий

И для более сложного анализа объединяем рейтинги в единый общий рейтинг, например, используя сумму рангов или взвешенные коэффициенты. Таким образом, запрос, приведённый на рис. 2.9, добавляет общий рейтинг total_rank как сумму рангов по стрессу и BMI, а затем сортирует профессии по общему рейтингу.

FreeBusta is knowledge
without borders!

2.4. Многомерная агрегация: комплексный взгляд на данные

Еще одним важным аспектом анализа данных является возможность создания многомерных отчетов, которые предоставляют детализированное представление информации по нескольким измерениям одновременно. В базовых инструментах, таких как Excel или Pandas, это достигается с помощью сводных таблиц или многоуровневой группировки. Однако SQL предлагает более мощные механизмы для многомерной агрегации, такие как операторы CUBE и ROLLUP, которые позволяют строить иерархические агрегации и автоматически добавлять промежуточные итоги.

Например, с помощью ROLLUP можно проанализировать продажи по регионам и категориям товаров, добавив общие итоги для каждого региона и категории. Такая возможность особенно ценна при работе с большими датасетами, где важно быстро получить сводную информацию на разных уровнях детализации.

Приведем результаты анализа по следующим агрегациям:

— среднее качество сна и средний уровень физической активности для каждой категории нарушений сна;

— общие средние значения по всем категориям.

```
SELECT COALESCE(sleep_disorder, 'ИТОГО по нарушениям сна') AS sleep_disorder,
    ROUND(AVG(quality_of_sleep), 3) AS avg_quality_sleep,
    ROUND(AVG(physical_activity_level), 3) AS avg_physical_activity
FROM shl
GROUP BY ROLLUP(sleep_disorder)
ORDER BY sleep_disorder;
```

Data Output

	sleep_disorder character varying	avg_quality_sleep numeric	avg_physical_activity numeric
1	Insomnia	6.532	46.818
2	None	7.626	57.950
3	Sleep Apnea	7.152	74.709
4	ИТОГО по нарушениям сна	7.301	59.195

Рисунок 2.10. Результаты анализа влияния нарушений сна на сон и активность

Функция COALESCE возвращает первое непустое значение из списка аргументов, если sleep_disorder равно NULL (в строке с итогами), то вместо него будет выведено сообщение. В SQL запросах с использованием GROUPING SETS, ROLLUP или CUBE, значения NULL в результатах возникают, когда данные агрегируются на более высоком уровне (например, подытоги или общий итог).

Как мы видим, ROLLUP автоматически добавляет итоговые строки, анализирует данные на разных уровнях детализации и весьма удобен для создания

FreeBusta is knowledge
without borders!

сводных отчетов. Для более сложного анализа можно использовать CUBE, который создает все возможные комбинации уровней агрегации (указанным измерениям).

Оператор CUBE позволяет одновременно получать данные на уровне детализации, частичные подитоги и общий итог. Например, если у вас есть два измерения (A и B), то CUBE(A, B) создаст группы для:

— (A, B) — детализированные данные;

— подитоги по каждому значению A (по всем значениям B);

— подитоги по каждому значению B (по всем значениям A);

— () — общий итог (по всем значениям A и B).

Это упрощает анализ данных, так как не нужно выполнять несколько запросов для получения различных уровней агрегации. Результаты запроса часто используются для создания сводных или кросс-таблиц, где строки и столбцы представляют различные измерения, а ячейки содержат агрегированные значения (например, суммы, средние значения).

В запросе (см. результаты на рис. 2.11) используем CUBE (physical_activity_level, sleep_disorder), чтобы получить все возможные комбинации уровней физической активности и типов нарушений сна.

```
SELECT
    COALESCE(sleep_disorder, 'ВСЕ НАРУШЕНИЯ СНА') AS sleep_disorder,
    ROUND(AVG(quality_of_sleep)::numeric, 2) AS avg_quality_sleep,
    COUNT(*) AS record_count
FROM
    shl
GROUP BY
    CUBE (physical_activity_level, sleep_disorder)
ORDER BY
    physical_activity_level NULLS LAST,
    sleep_disorder NULLS LAST;
```

Data Output

	sleep_disorder character varying	avg_quality_sleep numeric	record_count bigint
1	Insomnia	6.60	5
2	None	7.55	60
3	Sleep Apnea	4.67	3
4	ВСЕ НАРУШЕНИЯ СНА	7.35	68

Рисунок 2.11. Фрагмент результатов применения опции CUBE в запросе

Результат включает:

— детализированные данные для каждой пары значений (physical_activity_level, sleep_disorder);

FreeBusta is knowledge without borders!

— подитоги для каждого уровня активности (по всем нарушениям сна);
— подитоги для каждого типа нарушения сна (по всем уровням активности);
— общий итог (по всем уровням активности и всем нарушениям сна).

Были заменены NULL на текстовые метки, а именно, метка 'ВСЕ НАРУШЕНИЯ СНА' используется для обозначения подитогов или итогов по всем типам нарушений сна.

GROUPING SETS — это еще один мощный инструмент в SQL для выполнения агрегации данных. Он позволяет указать несколько наборов столбцов, по которым нужно группировать данные, и получать результаты агрегации для каждого из этих наборов в одном запросе. В отличие от ROLLUP и CUBE, которые создают автоматические комбинации уровней агрегации, GROUPING SETS дает полный контроль над тем, какие именно группы необходимо получить.

```
SELECT
    COALESCE(occupation, 'ИТОГИ') AS occupation,
    COALESCE(bmi_category, 'ВСЕ') AS bmi_category,
    ROUND(AVG(quality_of_sleep), 2) AS avg_quality_of_sleep,
    ROUND(AVG(stress_level), 2) AS avg_stress_level
FROM shl
GROUP BY GROUPING SETS (
        (occupation),          -- Группировка только по профессии
        (bmi_category),        -- Группировка только по категории ИМТ
        ())                    -- Общий итог
ORDER BY occupation, bmi_category;
```

Data Output

	occupation character varying	bmi_category character varying	avg_quality_of_sleep numeric	avg_stress_level numeric
1	Accountant	ВСЕ	7.89	4.59
2	Doctor	ВСЕ	6.65	6.73
3	Engineer	ВСЕ	8.41	3.89
4	Lawyer	ВСЕ	7.89	5.06
5	Manager	ВСЕ	7.00	5.00
6	Nurse	ВСЕ	7.37	5.55
7	Sales Representative	ВСЕ	4.00	8.00
8	Salesperson	ВСЕ	6.00	7.00
9	Scientist	ВСЕ	5.00	7.00
10	Software Engineer	ВСЕ	5.80	5.80
11	Teacher	ВСЕ	6.98	4.53
12	ИТОГИ	Normal	7.64	5.13
13	ИТОГИ	Normal Weight	7.43	5.19
14	ИТОГИ	Obese	6.40	5.70
15	ИТОГИ	Overweight	6.90	5.73
16	ИТОГИ	ВСЕ	7.30	5.38

Рисунок 2.12. Фрагмент результатов применения опции CUBE в запросе

Например, хотим проанализировать качество сна (quality_of_sleep) и уровень стресса (stress_level) следующими способами: по профессии (occupation), по категории ИМТ (bmi_category) и подвести общие итоги (для всех данных). За-

FreeBusta is knowledge without borders!

прос (см. рис. 2.12) агрегирует данные о качестве сна и уровне стресса по профессиям, категориям ИМТ и общему итогу, заменяя NULL на «ИТОГИ» и «ВСЕ» для удобства восприятия.

В заключении можно отметить, что ROLLUP создает иерархические уровни агрегации (подытоги и общий итог) и подходит для анализа данных *с фиксированной иерархией*. CUBE создает все возможные комбинации группировок и подходит для анализа данных *со всеми возможными пересечениями* (для всех комбинаций). GROUPING SETS же позволяет явно указать нужные наборы группировок и является самым гибким инструментом для точного контроля над агрегацией (*для выборочных группировок*).

Переход от базовых аналитических инструментов к SQL — это не просто замена одного инструмента другим, а логичное расширение возможностей анализа данных. SQL предоставляет:

— Производительность. Возможность обрабатывать большие объемы данных, минимизируя использование оперативной памяти.

— Гибкость. Поддержка сложных аналитических операций, таких как оконные функции и многомерная агрегация.

— Масштабируемость. Интеграция с базами данных, что позволяет работать с данными в реальном времени и поддерживать растущие объемы информации.

Таким образом, SQL становится естественным выбором для анализа данных, когда базовые инструменты перестают справляться с задачами. Он не только дополняет, но и усиливает возможности аналитики, открывая новые горизонты для исследования данных. Продемонстрированные в пособии аналитические sql-задачи можно прорешать в том числе на таких платформах, как LeetCode, HackerRank или Mode Analytics.

Отметим также, что базовые инструменты (например, pandas) и SQL могут дополнять друг друга: SQL используется для предварительной обработки данных, а pandas — для визуализации и дальнейшего анализа.

FreeBusta is knowledge
without borders!



3. ИНСТРУМЕНТЫ ДЛЯ АВТОМАТИЗАЦИИ МАШИННОГО ОБУЧЕНИЯ И СОЗДАНИЯ ИНТЕРАКТИВНЫХ ОТЧЕТОВ

3.1. Автоматическое машинное обучение с H2O Flow

H2O — это открытая платформа для машинного обучения и искусственного интеллекта, предоставляющая пользователям широкие возможности для разработки и анализа моделей. Одной из ключевых особенностей H2O является встроенный веб-интерфейс под названием Flow, который позволяет создавать модели машинного обучения без необходимости написания программного кода. Этот инструмент также поддерживает построение сложных конвейеров машинного обучения, упрощая процесс обработки данных и обучения моделей.

Кроме того, H2O предоставляет удобные API для интеграции с популярными языками программирования, такими как R, Python и Scala, что делает его универсальным решением для специалистов по данным и разработчиков. Благодаря своей гибкости и доступности, платформа активно используется как для исследовательских задач, так и для промышленного внедрения решений на основе ИИ.

Данная платформа применяется для реализации автоматического машинного обучения (AutoML), которое существенно упрощает процесс построения моделей. Благодаря AutoML, рутинные задачи по настройке и выбору моделей передаются системе, что позволяет специалистам по данным сконцентрироваться на более важных этапах работы. Это включает, например, создание новых признаков, оптимизацию конвейеров обработки данных и внедрение готовых моделей в производственную среду.

Устанавливаем платформу, выполняя следующие шаги:

1. Скачиваем дистрибутив H20: https://h2o-release.s3.amazonaws.com/h2o/rel-yates/5/index.html
2. Скачиваем дистрибутив Java: https://www.java.com/ru/download/uninstalltool.jsp
3. Выполняем от имени администратора команды:

```
cd ~/Downloads
распаковать h2o-3.24.0.5.zip cd h2o-3.24.0.5
выполнить java -jar h2o.jar
```

Но лучше из загрузок перенести распакованную папку на уровень диска, (например: C:\Users\ARMUser \h2o-3.24.0.5>D:\h2o-3.24.0.5\h2o.jar)

4. Перейти в браузере на http://localhost:54321/

FreeBusta is knowledge without borders!

Адрес изменяется на -> http://localhost:54321/flow/index.html и получаем стартовую страницу платформы.

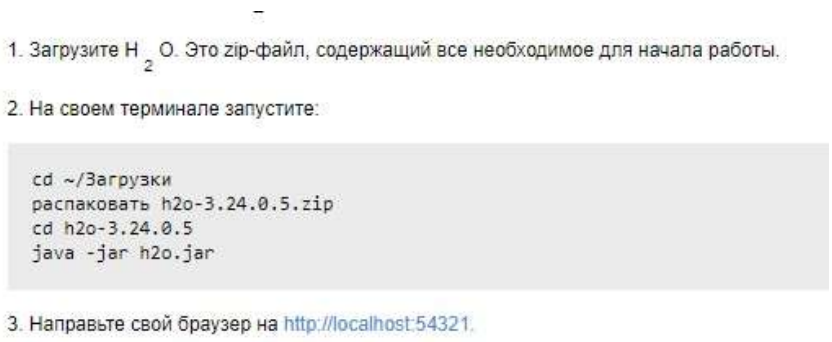


Рисунок 3.1. Шаги установки платформы H2O

Создадим собственную записную книжку Flow. Чтобы начать, выбираем пункт «Импорт файлов», указываем путь к файлу данных и запускаем процесс импорта. Также существует возможность загрузки данных из внешних источников, таких как HDFS или S3-хранилище. После импорта данные загружаются в память кластера H2O.

Если используется распределенная система (например, с несколькими узлами), данные автоматически распределяются между узлами для оптимизации обработки. Датасет преобразуется во внутренний формат H2O, называемый H2OFrame — это табличная структура данных, аналогичная dataframe в Python (pandas) или таблицам в R.

Платформа автоматически анализирует типы данных для каждого столбца (числовые, категориальные, временные и т.д.). Выполняется базовая проверка: выявляются пропущенные значения, выбросы и другие аномалии.

В интерфейсе Flow или через API можно просмотреть сводную информацию о датасете, включая:

— размер данных (количество строк и столбцов);
— статистические характеристики (среднее, минимум, максимум, стандартное отклонение для числовых признаков);
— распределение значений для категориальных признаков.

На следующем этапе выполняется подготовка данных.

H2O предоставляет следующие инструменты для предварительной обработки данных:

— заполнение пропущенных значений (например, средним, медианой или пользовательскими значениями);

FreeBusta is knowledge without borders!

— преобразование категориальных переменных в числовые (например, one-hot encoding или label encoding);
— нормализация или масштабирование числовых данных.

Эти операции могут выполняться как вручную, так и автоматически с использованием AutoML.

Переходим непосредственно к разделению данных на обучающую, валидационную и тестовую выборки. H2O позволяет легко выполнить это разделение с указанием нужных пропорций (например, 70% на обучение, 15% на валидацию и 15% на тестирование).

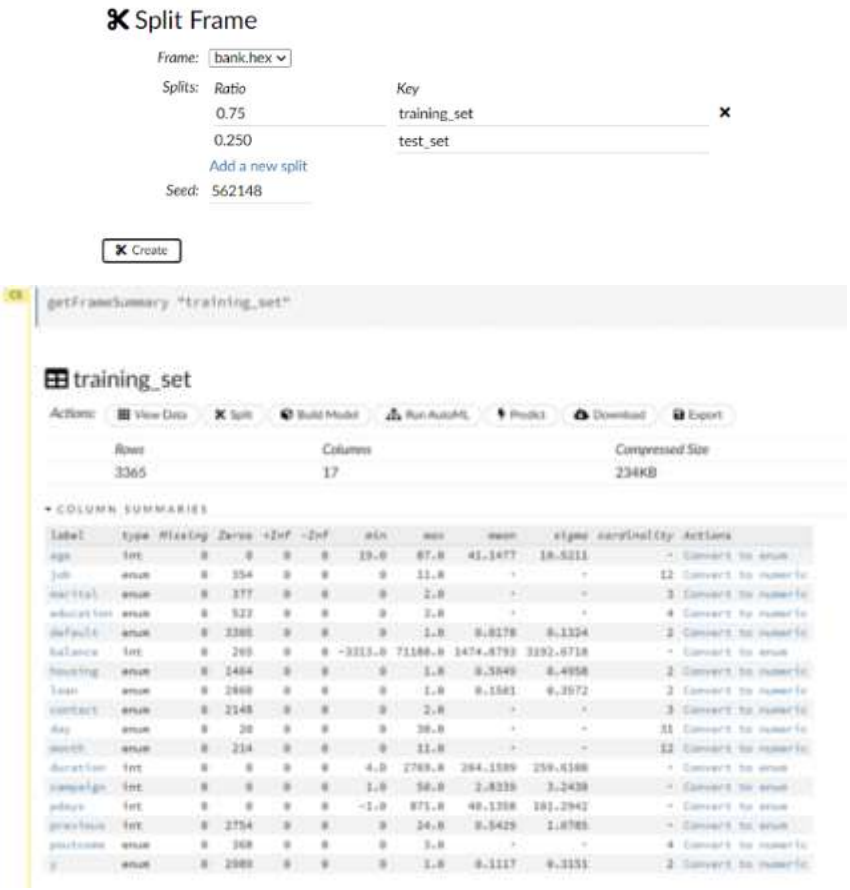


Рисунок 3.2. Разделение данных на обучающую и тестовую выборки

После подготовки данных можно приступить к обучению моделей. При использовании AutoML запускается автоматизированный процесс обучения, где H2O самостоятельно выбирает алгоритмы, обучает различные типы моделей, включая обобщённые линейные модели (GLM), распределенные случайные леса DRF, Gradient Boosting Machine (GBM), XGBoost, многослойный персептрон и составные ансамбли (стекинг Stacked Ensembles), настраивает гиперпараметры и строит несколько моделей.

FreeBusta is knowledge
without borders!



Рисунок 3.3. Автоматическое обучение

По умолчанию число перекрестной проверки равно 5. Поскольку наблюдается ситуация дисбаланса классов, можно выбрать опцию классов баланса.

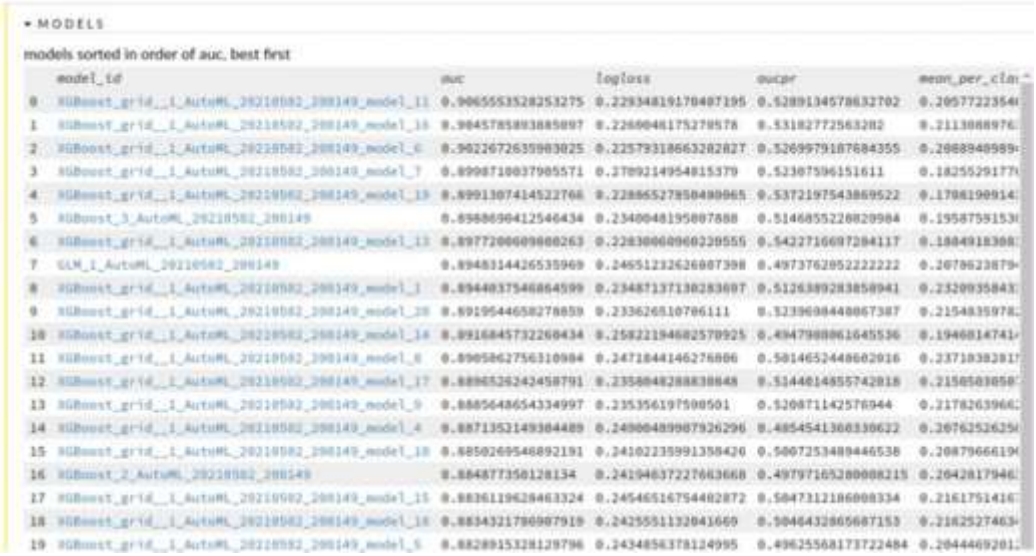
Также можно исключить определенные модели, если знаем, что они не актуальны. Изменяем max_runtime_seconds на 300 секунд. AutoML обучает модели до max_runtime_seconds, после чего он остановится (по умолчанию установлено значение 3600 секунд). Есть возможность просмотра обновлений моделей в реальном времени во время обучения. Можно видеть историю оценок в режиме реального времени с визуализацией обучения (графическими представлениями).



Рисунок 3.4. Процесс обучения

Также представлена таблица лидеров (рейтинг моделей) со всеми моделями, отсортированными по некоторым показателям, на основе их производительности (например, метрик AUC, RMSE, logloss и т.д.). На рис. 3.5 показан пример таблицы. В данном случае модель XGboost является лучшей моделью.

FreeBusta is knowledge
without borders!



▾ MODELS

models sorted in order of auc, best first

	model_id	auc	logloss	aucpr	mean_per_cla
0	XGBoost_grid__1_AutoML_20210502_200149_model_11	0.9065553528253275	0.22934819170407195	0.5289134578632702	0.2057722354
1	XGBoost_grid__1_AutoML_20210502_200149_model_10	0.9045785893885097	0.2260046175270578	0.53182772563202	0.211308897
2	XGBoost_grid__1_AutoML_20210502_200149_model_6	0.9022672635903025	0.22579318663282827	0.5269979187684355	0.2088940989
3	XGBoost_grid__1_AutoML_20210502_200149_model_7	0.8998710037905571	0.2709214954815379	0.52307596151611	0.1825529177
4	XGBoost_grid__1_AutoML_20210502_200149_model_19	0.8991307414522766	0.22866527850490965	0.5372197543869522	0.1708190914
5	XGBoost_3_AutoML_20210502_200149	0.8968690412546434	0.2340048195807888	0.5146855226820984	0.1958759153
6	XGBoost_grid__1_AutoML_20210502_200149_model_13	0.8977200609808263	0.22830060960220555	0.5422716697284117	0.1884918388
7	GLM_1_AutoML_20210502_200149	0.8948314426535969	0.24651232626007398	0.4973762052222222	0.2079623879
8	XGBoost_grid__1_AutoML_20210502_200149_model_1	0.8944037546864599	0.23487137130283697	0.5126389283858941	0.2320935843
9	XGBoost_grid__1_AutoML_20210502_200149_model_20	0.8919544658278859	0.233626510706111	0.5239698448867387	0.2154835978
10	XGBoost_grid__1_AutoML_20210502_200149_model_14	0.8916845732268434	0.25822194682570925	0.4947988061645536	0.1946814741
11	XGBoost_grid__1_AutoML_20210502_200149_model_8	0.890586275631098	0.2471844146276806	0.5014652448602016	0.2371838281
12	XGBoost_grid__1_AutoML_20210502_200149_model_17	0.8896526242458791	0.2358848288838848	0.5144614855742818	0.2150503858
13	XGBoost_grid__1_AutoML_20210502_200149_model_9	0.8885648654334997	0.235356197500501	0.520871142576944	0.2178263966
14	XGBoost_grid__1_AutoML_20210502_200149_model_4	0.8871352149304489	0.24000489907926296	0.4854541366330622	0.2076252625
15	XGBoost_grid__1_AutoML_20210502_200149_model_18	0.8850269546892191	0.24102235991358420	0.5007253489446538	0.2087966619
16	XGBoost_2_AutoML_20210502_200149	0.884877350128134	0.24194637227663668	0.4979716528000821	0.2042817946
17	XGBoost_grid__1_AutoML_20210502_200149_model_15	0.8836119628463324	0.24546516754402872	0.5047312186008334	0.2161751416
18	XGBoost_grid__1_AutoML_20210502_200149_model_16	0.8834321790987919	0.2425551132041669	0.5046432865687153	0.2162527463
19	XGBoost_grid__1_AutoML_20210502_200149_model_5	0.8828915328129796	0.2434856378124995	0.49625568173722484	0.2044469201

Рисунок 3.5. Таблица лидеров

AutoML обеспечивает визуализацию различных показателей, которые можно использовать для исследования модели. Щёлкнув по кривой, узнаём о ней более подробную информацию.

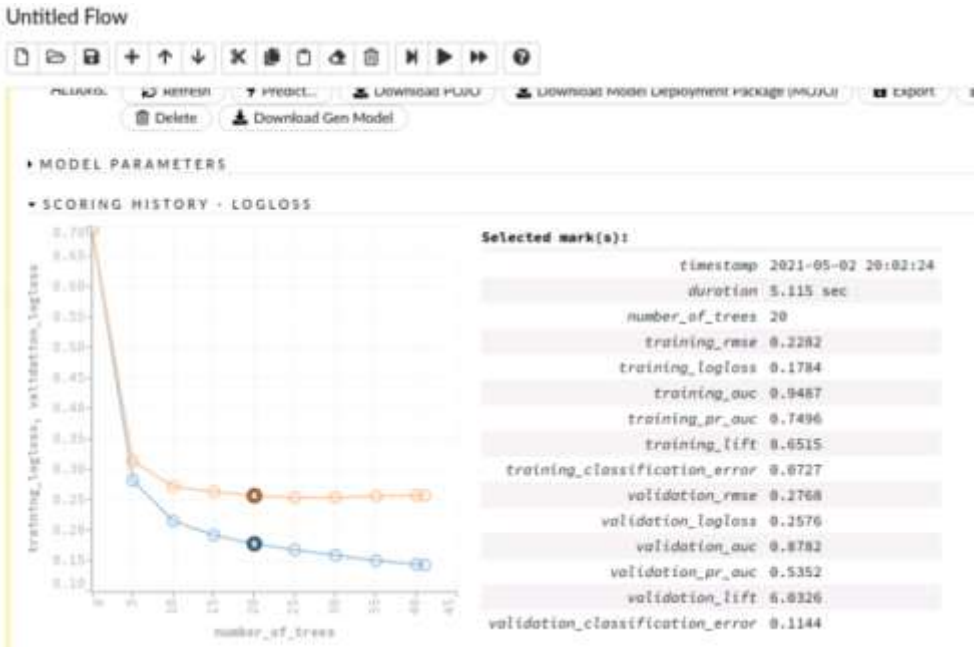


Рисунок 3.6. Визуализация метрики logloss

Можно проверить важность переменных. На рис. 3.7 видим, что переменная продолжительность контакта очень предсказуема и используется в этой модели

FreeBusta is knowledge
without borders!

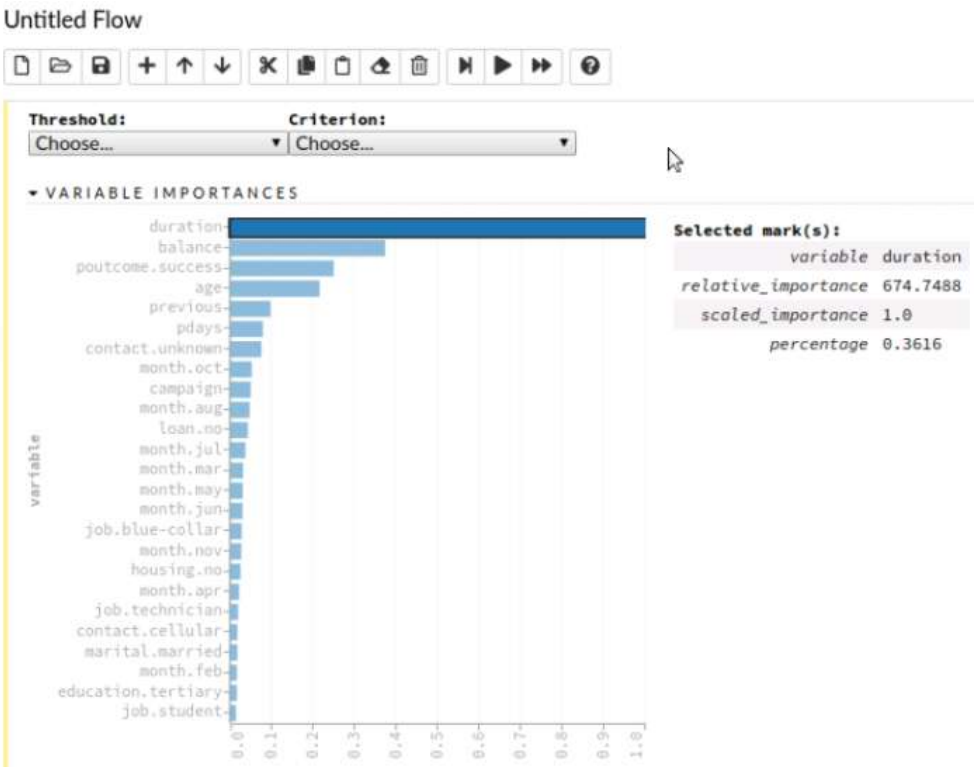


Рисунок 3.7. Визуализация важности признаков

В платформе H2O матрица ошибок (confusion matrix) является важным инструментом для оценки производительности модели классификации. Она показывает, как модель классифицирует объекты по сравнению с их истинными метками.

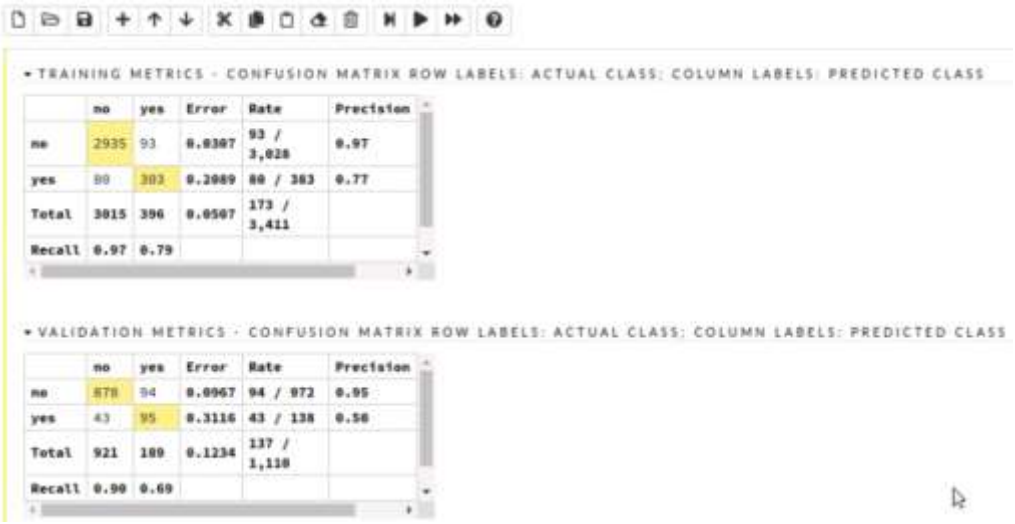


Рисунок 3.8. Визуализация матрицы ошибок

После оценки качества модели, если удовлетворены выбором, можно переходить к прогнозам. Начинаем с выбора параметра прогнозирования на панели инструментов и выбираем модель, которую хотим далее использовать, а затем выбираем фрейм проверки, как показано на рис. 3.9.

FreeBusta is knowledge
without borders!

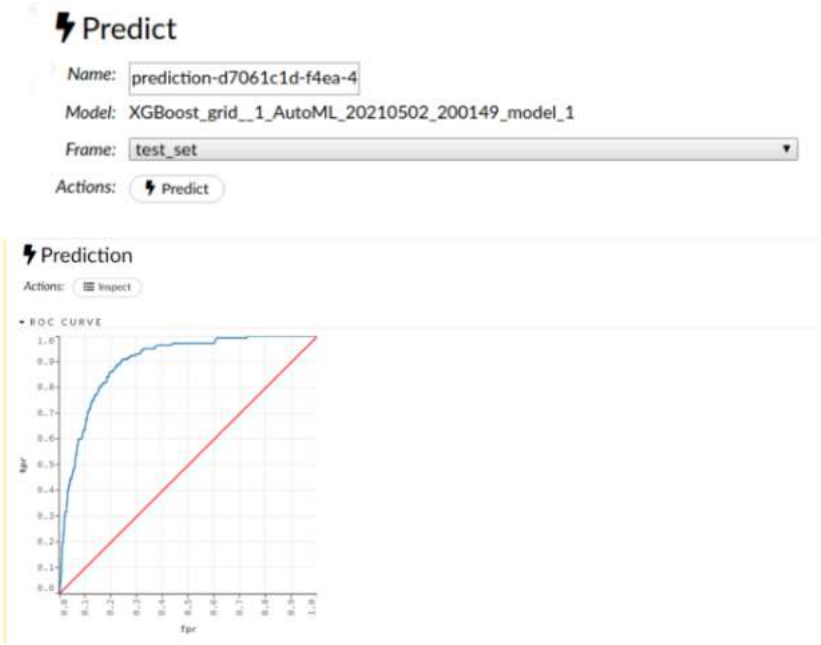


Рисунок 3.9. Оценка качества модели с помощью roc curve

При ручном моделировании у аналитика есть возможность выбрать конкретный алгоритм (например, GBM, GLM, Deep Learning, XGBoost и др.) и настроить его параметры вручную.

По итогам обучения модели можно оценить их качество с помощью различных метрик (например, точность, полнота, F1-мера, ROC-AUC и др.). H2O также предоставляет визуализации, такие как графики важности признаков, кривые ошибок, матрицы ошибок и другие инструменты для анализа результатов.

Обученные модели можно экспортировать в различных форматах (например, POJO или MOJO) для дальнейшего использования в production-средах. Также поддерживается интеграция с внешними системами через API для прогнозирования на новых данных.

H2O предоставляет и дополнительные возможности, позволяя проводить эксперименты с данными, создавать конвейеры машинного обучения и повторно использовать компоненты для других задач. Через интерфейс Flow все этапы работы с данными и моделями можно документировать и воспроизводить.

Таким образом, использование AutoML помогает повысить эффективность работы и сократить временные затраты.

3.2. Взаимодействие с данными и процессами в RapidMiner

RapidMiner — это универсальная платформа для работы с данными, которая охватывает широкий спектр задач: от анализа данных и машинного обучения до прогнозной аналитики и бизнес-аналитики. Проект был запущен в 2001 году группой исследователей из Технического университета Дортмунда, а с 2007 года

FreeBusta is knowledge
without borders!

он стал одним из ключевых инструментов для анализа данных как в академической среде, так и в промышленности.

RapidMiner предоставляет пользователям мощный графический интерфейс, который позволяет создавать, тестировать и внедрять аналитические модели без необходимости написания кода. Программа работает с процессами, которые представляют собой последовательности задач, записанных в xml-формате. Эти процессы строятся из более чем 500 встроенных операторов, каждый из которых выполняет определенную функцию: от загрузки и предобработки данных до моделирования и визуализации результатов.

Одним из главных преимуществ RapidMiner является его гибкость и удобство использования. Платформа поддерживает работу с различными типами данных (текст, изображения, аудио) и позволяет интегрировать данные из различных источников, таких как базы данных, облачные хранилища или потоки данных в реальном времени. Благодаря визуальному конструктору рабочих процессов, пользователи могут легко комбинировать операторы, создавая сложные аналитические пайплайны.

Платформа предлагает расширяемость через Marketplace, где можно найти дополнительные операторы и инструменты для специализированных задач, таких как анализ временных рядов или обработка данных из социальных сетей. Платформа поддерживает параллельное выполнение задач, что ускоряет обработку больших объемов данных.

Turbo Prep — это модуль RapidMiner Studio, предназначенный для упрощения и автоматизации процесса подготовки данных (data preparation), который помогает очистить и преобразовать данные, объединить несколько источников данных и создать новые признаки (feature engineering), а также подготовить данные для дальнейшего анализа или построения моделей машинного обучения.

Основные понятия RapidMiner включают:

Процесс – последовательность операторов, объединенных для выполнения конкретной задачи.

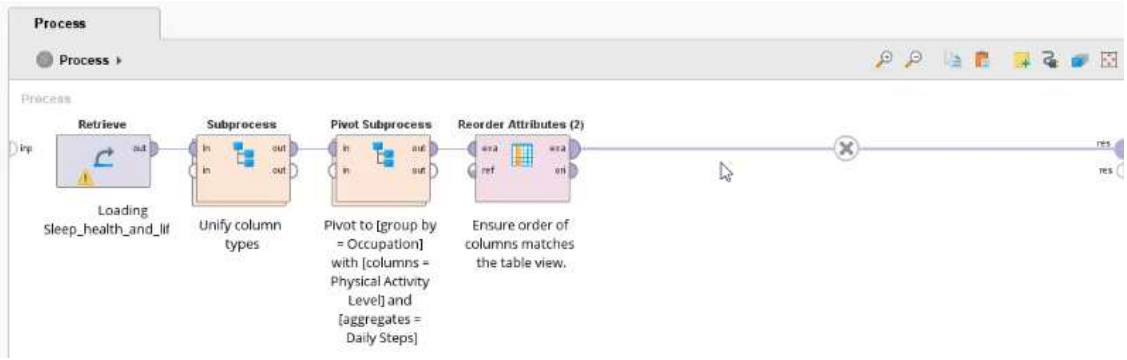


Рисунок 3.10. Конструктор рабочих процессов

FreeBusta is knowledge without borders!

Оператор – базовый элемент процесса, который выполняет определенные действия с данными.

Репозиторий – место для хранения процессов и данных, которое может быть локальным или удаленным.

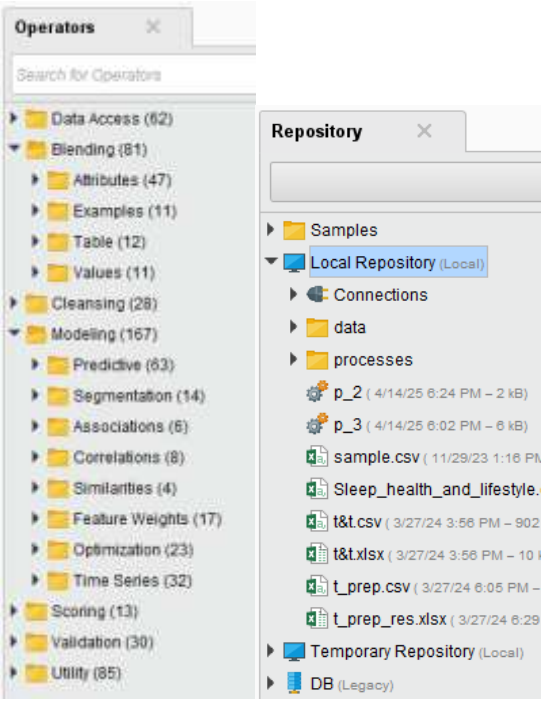


Рисунок 3.11. Панели выбора операторов. Репозитории платформы Rapidminer

Контекст процесса – настройки входных и выходных данных, а также глобальные переменные (макросы), доступные в процессе.

Интерфейс программы разделен на несколько функциональных областей: слева расположены панели для загрузки данных и выбора операторов, в центре находится рабочая область, где создаются процессы путем перетаскивания операторов и данных, справа находятся параметры выбранных операторов и документация.

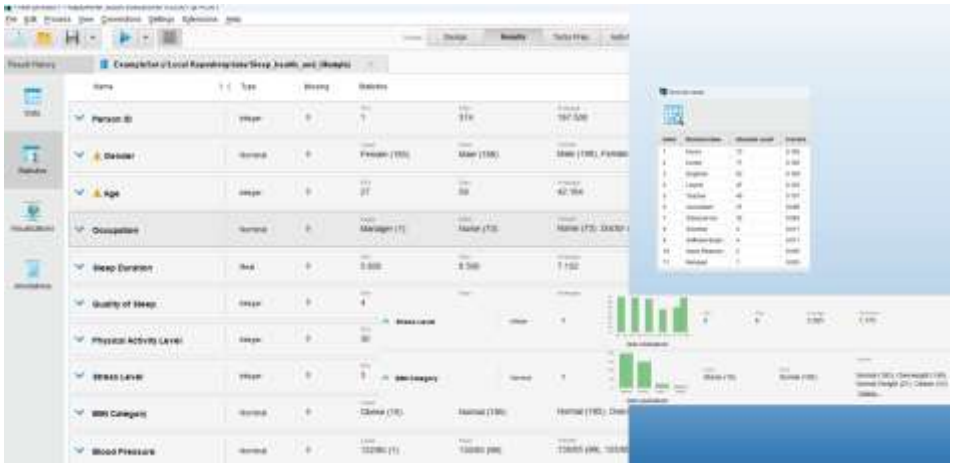


Рисунок 3.12. Подготовка данных

FreeBusta is knowledge
without borders!

RapidMiner анализирует данные, выбирает подходящие алгоритмы, настраивает гиперпараметры и строит модель, минимизируя усилия пользователя.

Основные этапы:

1) *загрузка данных из различных источников*. RapidMiner автоматически анализирует структуру данных, типы переменных (числовые, категориальные) и обнаруживает пропущенные значения;
2) *настройка задачи*, где указывается цель моделирования;
3) *автоматический выбор модели* с помощью **AutoModel** (например, деревья решений, случайный лес, градиентный бустинг, нейронные сети и др.). Инструмент также выполняет предобработку данных (нормализация, заполнение пропусков, кодирование категориальных переменных), разделение данных на обучающую и тестовую выборки, оптимизацию гиперпараметров (см. рис. 3.13).

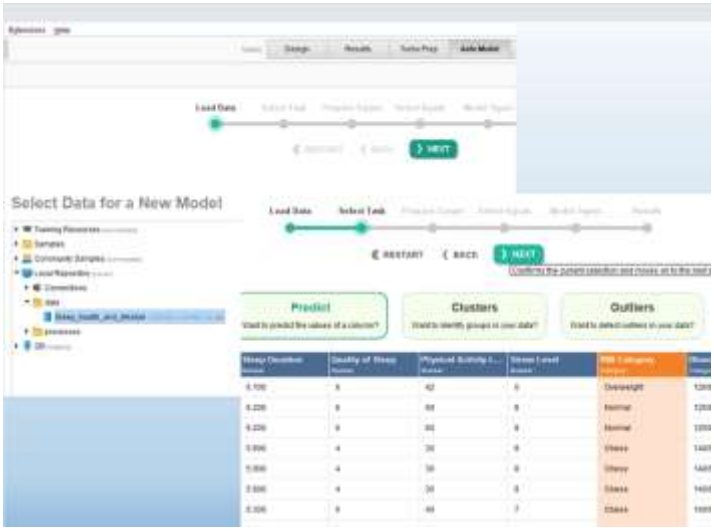


Рисунок 3.13. Процесс автоподбора оптимальной модели машинного обучения

4) *оценка модели с предоставлением отчетов* с метриками качества модели (например, точность, F1-score, MAE и т.д.), можно визуализировать результаты и сравнить производительность разных моделей.
5) *использование модели*, которую можно сохранить и использовать для прогнозирования новых данных. RapidMiner также позволяет экспортировать модель в формате PMML (Predictive Model Markup Language) для использования в других системах (см. рис. 3.14).

FreeBusta is knowledge
without borders!



Рисунок 3.14. Результаты автомоделирования. Таблица лидеров

Язык разметки прогнозных моделей PMML, был разработан 18 лет назад и получил широкое распространение среди компаний, предоставляющих программное обеспечение для анализа данных. Этот формат, основанный на XML, стал стандартом де-факто для описания как результатов этапа моделирования, так и предварительной обработки данных, необходимой для того, чтобы модель могла использоваться для выполнения прогнозов.

RapidMiner широко используется в университетах для обучения основам анализа данных и в компаниях для решения практических задач, таких как обнаружение спама, классификация дефектов продукции или анализ пользовательского поведения на сайтах. Благодаря своей универсальности и удобству, RapidMiner значительно упрощает процесс анализа данных, делая его доступным как для новичков, так и для опытных аналитиков.

3.3. Сценарий обработки данных в Loginom

Loginom — аналитическая платформа, которая предоставляет инструменты для проведения глубокого анализа данных и помогает принимать управленческие решения, основанные на точных и достоверных данных. Основные функции платформы включают выполнение сложных расчетов, объединение данных из различных источников, очистку информации, прогнозирование, оптимизацию данных, а также интеграцию с любыми хранилищами данных. Среди поддержи-

FreeBusta is knowledge
without borders!

ваемых источников — базы данных, отдельные файлы, учетные системы, социальные сети и веб-сервисы. Платформа сочетает в себе как структурный, так и объектно-ориентированный подходы к моделированию, что делает её гибкой и универсальной.

Пакет — основной элемент платформы Loginom. Все действия в Loginom Studio происходят внутри Пакета, который является минимальной единицей доставки и контейнером для компонентов, сценариев и подключений. Пакеты сохраняются как файлы *.lgp и включают Ссылки и Модули.

Сценарий в Loginom представляет собой последовательность взаимосвязанных узлов, каждый из которых выполняет определенную операцию над данными. Сценарий строится визуально: пользователь добавляет необходимые компоненты (например, для обработки данных, выполнения расчетов или подключения к источникам) в рабочую область, где они преобразуются в узлы. Каждый узел может иметь входы и выходы, через которые он взаимодействует с другими узлами. Входы принимают данные (таблицы, переменные или подключения), а выходы возвращают результаты обработки. Порты входов и выходов различаются в зависимости от типа данных и несовместимы между собой. Число входов и выходов зависит от функционала узла, а их настройка может происходить автоматически или вручную. Сценарий используется для реализации аналитических задач, таких как очистка данных, трансформация, анализ, прогнозирование или интеграция данных из разных источников. Он является основным инструментом моделирования процессов в Loginom и позволяет создавать сложные цепочки обработки данных в наглядной форме.

В данном разделе мы рассмотрим основные возможности работы с PostgreSQL в Loginom, а также операции, которые можно выполнять для анализа данных.

Первым шагом является настройка подключения к базе данных PostgreSQL. Для этого в Loginom создается соединение (connection) с типом “PostgreSQL”, где необходимо указать параметры подключения: хост (адрес сервера PostgreSQL), порт (по умолчанию 5432), имя базы данных, имя пользователя и пароль, далее возможно, дополнительные параметры (например, таймаут подключения).

FreeBusta is knowledge
without borders!



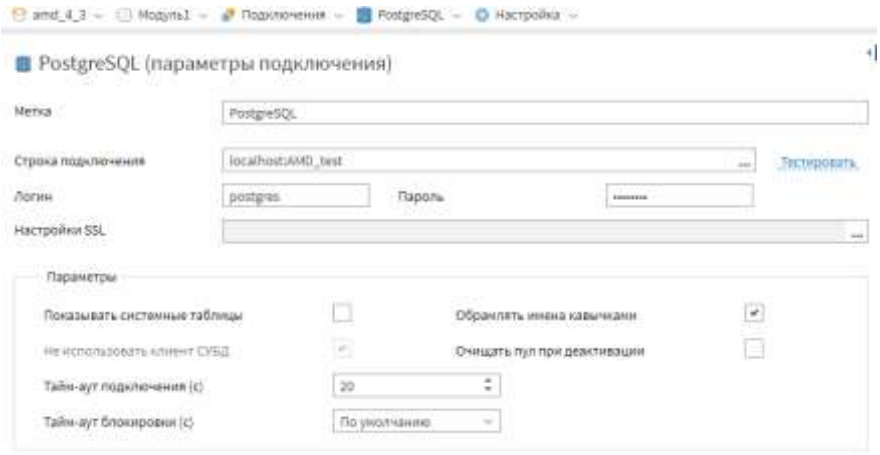


Рисунок 3.15. Подключение к СУБД Postgres

После успешного подключения вы сможете видеть структуру базы данных (схемы, таблицы, представления) в интерфейсе Loginom.

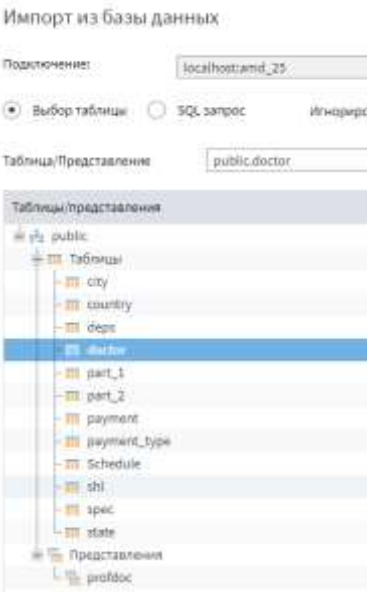


Рисунок 3.16. Структура БД в Postgres

Можно выполнять следующие операции:

а) *Извлечение данных*: выбор данные из таблиц или представлений, использование SQL-запросов для выполнения сложных выборок, фильтрация данных на уровне базы данных или уже в Loginom.

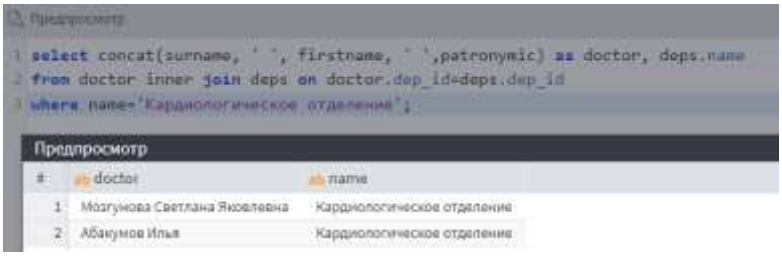


Рисунок 3.17. Использование sql для извлечения данных

FreeBusta is knowledge
without borders!

б) *Преобразование данных*: выполнение ETL-операций, удаление ненужных строк или столбцов, группировка данных и вычисление сумм, средних значений и других метрик, соединение данных из нескольких таблиц (JOIN) и создание новых вычисляемых полей на основе существующих данных.

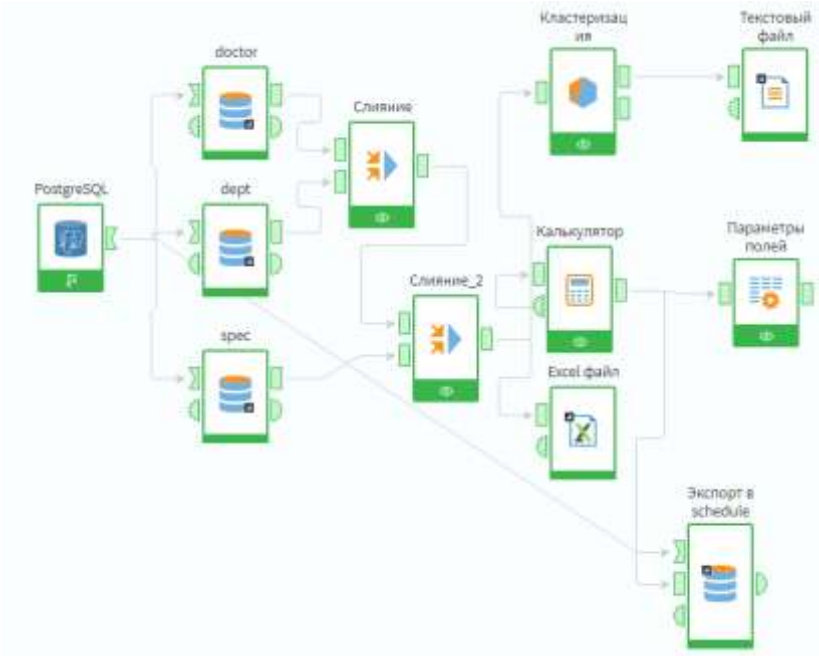


Рисунок 3.18. Пример сценария

На рис. 3.18 сценарий демонстрирует комплексную работу с данными в платформе Loginom. Он включает этапы извлечения, преобразования, анализа и автоматизированного экспорта данных.

Общая логика сценария:

1) Извлечение данных из PostgreSQL.
2) Объединение данных из нескольких таблиц.
3) Кластеризация для группировки данных по признакам.
4) Вычисление новых метрик для обогащения данных.
5) Настройка формата данных для удобства использования.
6) Сохранение промежуточных результатов в csv-файле.
7) Автоматизированный экспорт новой таблицы.

Итак, сценарий начинается с подключения к базе данных PostgreSQL. Данные из трех таблиц (doctor, dept, spec) объединяются через операцию «Слияние», это позволяет соединить информацию из разных таблиц на основе ключевых полей. Объединенные данные передаются в модуль «Кластеризация», где выполняется группировка данных по определенным признакам. Кластеризация основана на специализации врачей, также можно на частоте приемов пациентов. Ре-

FreeBusta is knowledge
without borders!

зультатом кластеризации будет разделение данных на группы с похожими характеристиками. Loginom предоставляет инструменты для быстрого анализа данных и поддерживает интеграцию с моделями машинного обучения. Описательная статистика выполняется на уровне подсчета количества записей, уникальных значений, пропущенных значений, также расчет минимальных, максимальных, средних значений и построение гистограмм и распределений. Возможно обучение моделей классификации, регрессии, кластеризации на данных из PostgreSQL, выполнение прогнозирования и анализа результатов.

Далее по сценарию, в модуле «Калькулятор» (рис. 3.19) вычисляются новые поля или метрики на основе существующих данных. В данном случае формируется колонка Расписание приёма. Этот шаг позволяет обогатить исходные данные новыми аналитическими метриками.

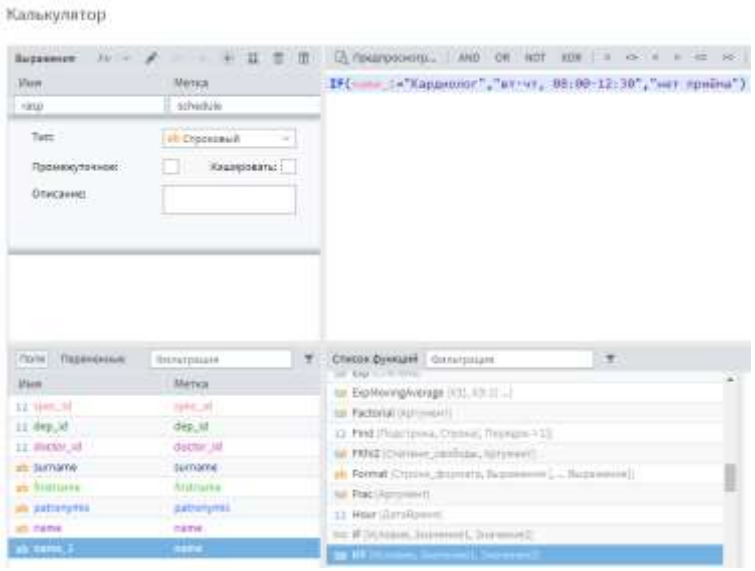


Рисунок 3.19. Ввод формулы для вычисляемого поля

spec_id	dep_id	doctor_id	surname	firstname	patronymic	name	name	schedule
1	12	1	Федоров	Илья	Васильевич	Пульмонологическое отделение	Терапевт	нет приёма
33	11	2	Мозгунова	Светлана	Яковлевна	Кардиологическое отделение	Кардиолог	вт-чт, 08:00-12:30
55	13	3	Крапивова	Екатерина	Игоревна	Гастроэнтерологическое отделение	Трихолог	нет приёма
1	12	4	Фёдорова	Светлана	Фёдоровна	Пульмонологическое отделение	Терапевт	нет приёма
33	11	5	Абакумов	Илья		Кардиологическое отделение	Кардиолог	вт-чт, 08:00-12:30

Рисунок 3.20. Результат вычислений

С помощью визуализатора Статистика можно просмотреть различные статистические показатели по каждому полю набора данных. Получим полный список доступных статистических показателей (рис. 3.21), большинство из них рассчитываются для полей вещественного, числового типов, а также типа дата/время. Но есть показатели статистики для строковых полей (минимальная, максимальная и средняя длина строки).

FreeBusta is knowledge
without borders!

Диаграмма размаха доступна только для полей вещественного типа и типа Дата/время, уникальные значения рассматриваются только для полей с дискретным видом данных, гистограмма не отображается если в поле большое количество уникальных значений.

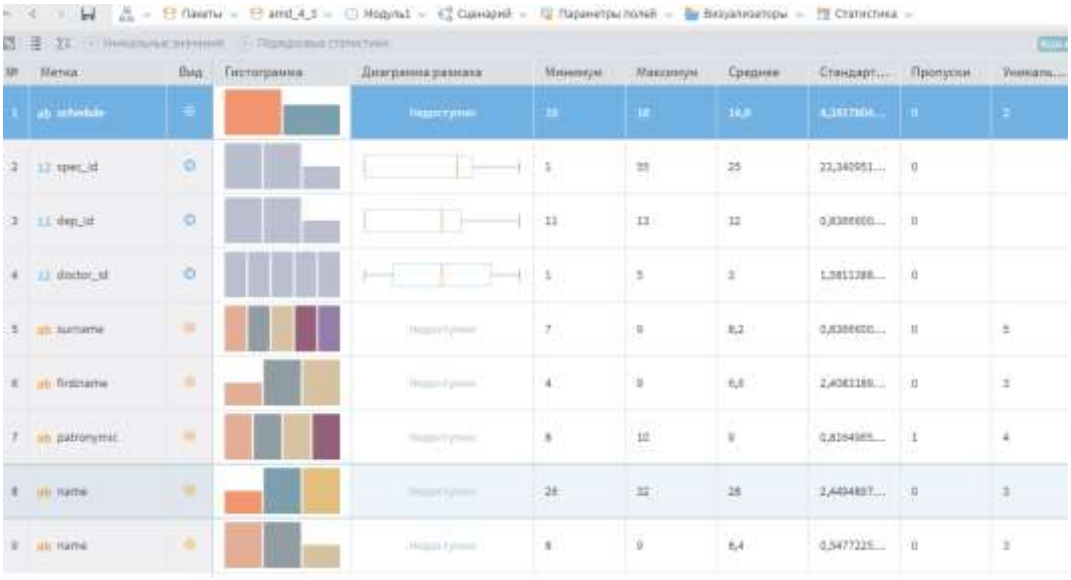


Рисунок 3.21. Визуализатор «Статистика»

Loginom предлагает широкие возможности для визуализации данных, это и столбчатые диаграммы, круговые диаграммы, линейные графики, тепловые карты для анализа корреляций, интерактивные дашборды для отображения ключевых метрик.

Возможно создавать скрипты для регулярного извлечения и анализа данных, настраивать триггеры для выполнения задач по расписанию и интегрировать эти задачи с внешними системами (например, отправка отчетов по email).

Модуль «Параметры полей» используется для настройки формата и типа данных в столбцах. Это может быть преобразование даты из одного формата в другой, изменение типа данных (например, строка → число) или удаление ненужных столбцов/ переименование существующих. Данный шаг важен для подготовки данных к последующей обработке или экспорту.

c) *Загрузка данных*: поддержка загрузки данных обратно в PostgreSQL, создание новых таблиц или обновление существующих, загрузка данных в формате CSV или других поддерживаемых форматах.

FreeBusta is knowledge
without borders!

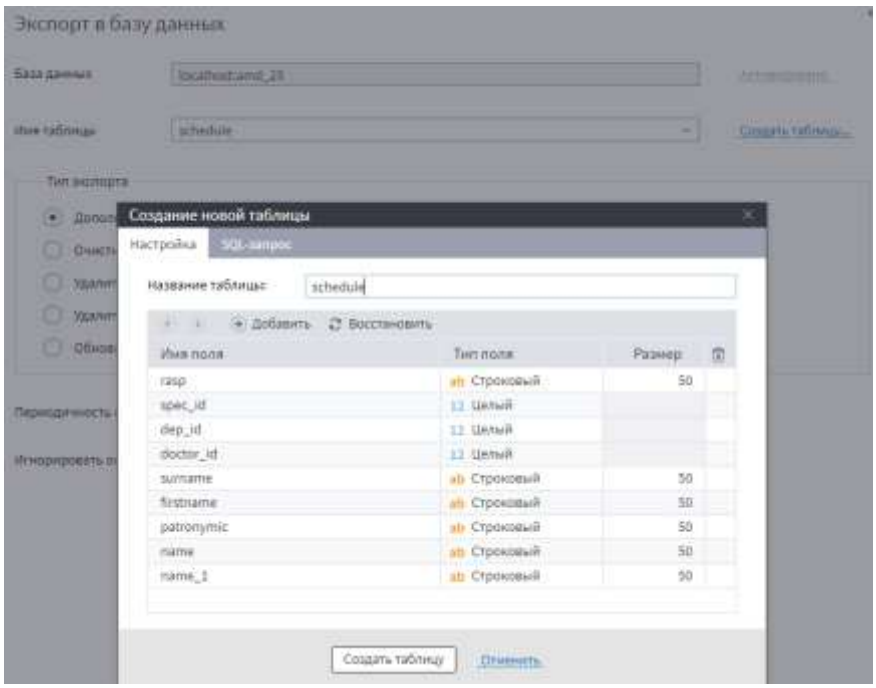


Рисунок 3.22. Экспорт новой таблицы schedule в целевую БД

В завершение можно отметить, что производительность обработки данных БД в Loginom может зависеть от мощности сервера БД и скорости сети. Остальные проблемы производительности можно решить на стороне сервера БД, например, настраивать индексы в БД для оптимизации запросов. Также некоторые сложные аналитические задачи могут потребовать дополнительных знаний SQL или Python.

3.4. Инструменты платформы KNIME Analytics Platform

KNIME — универсальная платформа для работы с данными на всех этапах анализа. В дополнение к созданию рабочих процессов, коммерческие пользователи применяют KNIME для защиты конфиденциальных данных, контроля и мониторинга моделей ИИ, а также для проверки и интерпретации полученных результатов.

Платформа использует подход «перетаскивания» для создания рабочих процессов (workflow). Пользователи могут строить цепочки операций, комбинируя узлы (nodes), каждый из которых выполняет определенную задачу (например, загрузка данных, преобразование, анализ или визуализация).

Поддерживает подключение к базам данных (SQL, NoSQL), файловым системам (CSV, Excel, JSON), облачным сервисам (AWS, Azure), социальным сетям и API. Включает инструменты для создания, обучения и тестирования моделей машинного обучения. Интегрируется с популярными библиотеками, такими как scikit-learn, tensorflow, keras, XGboost и другими, поддерживает написание

FreeBusta is knowledge
without borders!

собственных узлов на языках программирования, таких как Python, R, Java и JavaScript. Позволяет проверять качество аналитических моделей, мониторить их производительность и объяснять результаты прогнозов.

KNIME, как ранее было отмечено, обеспечивает защиту конфиденциальных данных благодаря функциям шифрования, анонимизации и контроля доступа.

Подготавливает данные для инструментов бизнес-аналитики (Power BI, Tableau и др.).

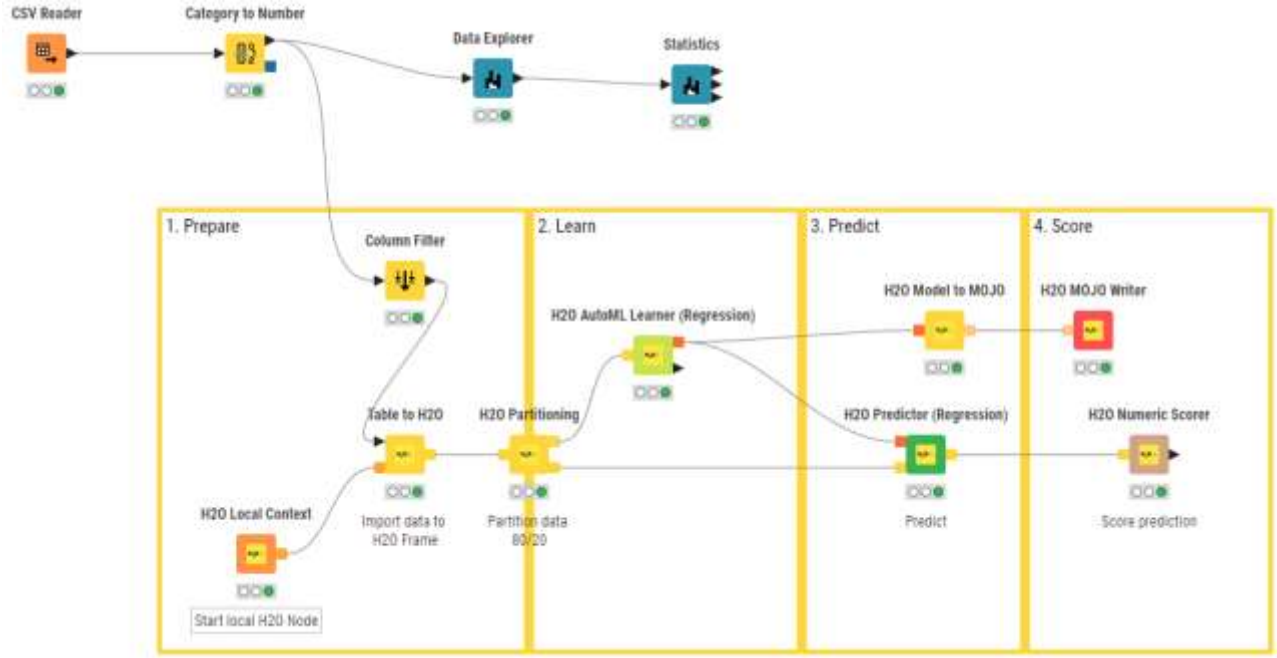


Рисунок 3.23. Обучение модели регрессии с использованием AutoML H2O

На рис. 3.23 изображен поток данных (workflow) для машинного обучения, выполненный с использованием платформы H2O и инструментов для обработки данных. Этот процесс можно разделить на несколько этапов:

1. *Подготовка данных* (Prepare) начинается с импорта анализируемых данных. Начальный узел CSV Reader считывает данные из csv-файла. Выделив компоненту,в нижней части окна можно просмотреть/ изменить данные датасета, о второй вкладке отображается статистика по нему/ Преобразование категориальные переменные в числовые значения выполняем с помощью узла Category to Number, что необходимо для дальнейшей обработки. Column Filter фильтрует столбцы данных, оставляя только те, которые необходимы для анализа или моделирования. Узел H2O Local Context запускает локальный контекст H2O, где будут выполняться вычисления. Далее импортируем (узел Import data to H2O Frame) подготовленные данные в формат H2O Frame, который используется для работы с данными в H2O.

FreeBusta is knowledge
without borders!

2. *Обучение модели* (Learn) с применением инструментария платформы H2O требует преобразования таблицы данных в формат H2O Frame, для чего с поток добавляется узел Table to H2O. H2O Partitioning разделяет данные на обучающую и тестовую выборки (в данном случае соотношение 80/20). Затем выполняем автоматическое обучение моделей регрессии с использованием AutoML от H2O (узел H2O AutoML Learner (Regression), позволяющий автоматически подбирать лучшую модель на основе предоставленных данных.

3. *Предсказание* (Predict). Данный этап начинаем с конвертации обученной модели в формат mojo (model optimized java object), который является оптимизированной версией модели для быстрого предсказания (H2O model to mojo) и затем используем обученную модель для генерации предсказаний на новых данных (узел H2O Predictor (Regression).

4. *Оценка результатов* (Score). Здесь, предварительно сохранив (H2O MOJO Writer) модель в формате mojo для последующего использования, оцениваем (H2O Numeric Scorer) качество предсказаний, используя метрики для числовых данных (например, RMSE, MAE).

В рассматриваемом примере для дополнительного анализа входных данных были использованы узлы для исследования данных Data Explorer, который выполняет обзор структуры данных, показывает размерность датасета, отображает типы данных (числовые, категориальные и т.д.), предоставляет базовые статистики (среднее, минимум, максимум, стандартное отклонение и т.д.) для числовых переменных и распределение значений для категориальных переменных и визуализирует распределения. С его помощью мы видим графики распределения для числовых и категориальных признаков (гистограммы, boxplot'ы), визуально выявляем выбросы или аномалии. Проверяем пропущенные значения, анализируя доли пропусков в каждом столбце, визуализируем пропущенные данные (например, heatmap), выполняем корреляционный анализ, вычисляя корреляции между числовыми переменными и отображая тепловую карту корреляций для лучшего понимания зависимостей. Таким образом, Data Explorer помогает быстро оценить качество данных, выявить проблемы (пропуски, выбросы) и понять их структуру перед дальнейшей обработкой.

Результаты исследования данных передаются на узел (Statistics) для расчета статистических характеристик данных (см. рис. 3.24).

FreeBusta is knowledge
without borders!



Рисунок 3.24. Таблица статистических характеристик данных

Statistics вычисляет основные статистические характеристики данных, такие как среднее, медиана, минимум, максимум, стандартное отклонение и дисперсия, количество пропущенных значений, частоты для категориальных переменных. Позволяет быстро получить числовую сводку по каждому признаку.

Приведённый пример предназначен для автоматической обработки данных, обучения модели регрессии с использованием AutoML, генерации предсказаний и оценки их качества. Такой подход особенно полезен при работе с большими объемами данных и когда требуется автоматизировать процесс создания и применения моделей машинного обучения.

И в дополнение для краткого обзора функционала платформы хотелось бы привести ещё пример, демонстрирующий комплексный анализ данных и создание эффективных моделей машинного обучения (см. рис. 3.25).

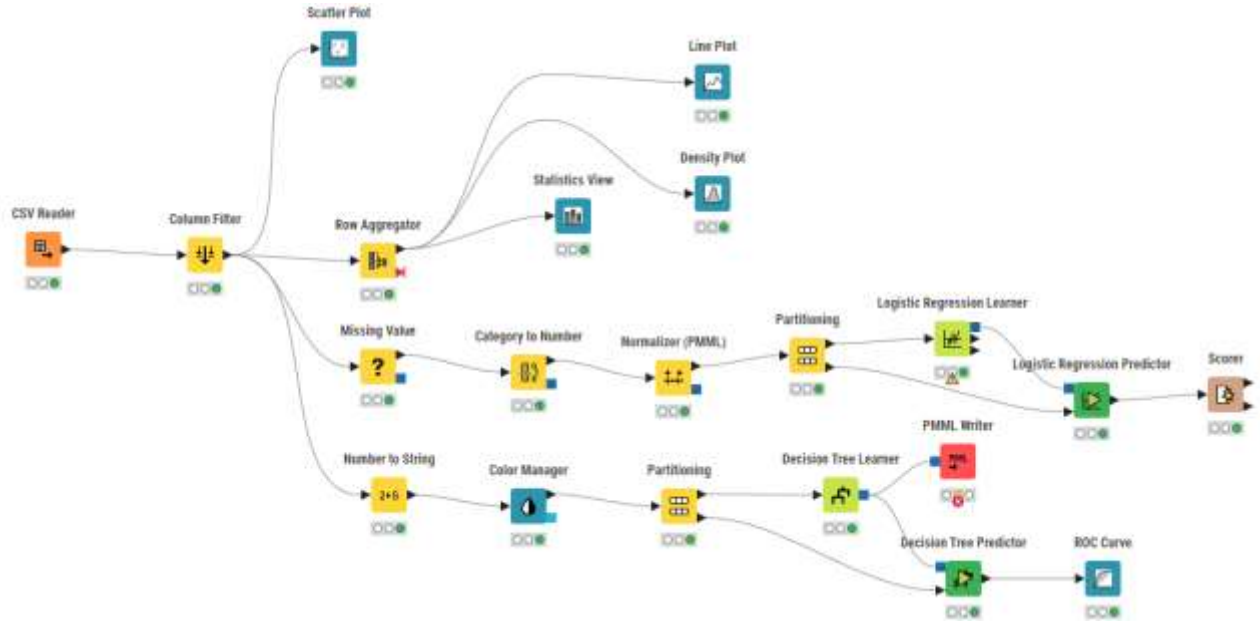


Рисунок 3.25. Полный цикл работы с данными

Этот процесс также включает несколько ключевых этапов: подготовку данных, анализ данных, разбиение на выборки, обучение моделей машинного обучения, предсказание и оценку результатов. Процесс начинается с чтения данных из csv-файла. Узел Column Filter фильтрует столбцы данных, оставляя только те,

FreeBusta is knowledge
without borders!

которые необходимы для дальнейшего анализа или моделирования, что помогает уменьшить размер данных и сосредоточиться на важных признаках.

Далее показано *разветвление потоков* обработки и анализа данных. Предварительно выполняем визуальный анализ полученных данных при помощи Scatter Plot, создающего диаграмму рассеяния для визуального анализа взаимосвязей между двумя числами признаками и позволяющего выявить корреляции или зависимости между переменными.

Во втором случае, Row Aggregator объединяет строки данных по определенным критериям. Например, может использоваться для агрегации данных по группам или вычисления статистик для каждой группы. Применяя Line Plot, изучаем график линий, который используется для отображения временных рядов или других последовательностей данных. Density Plot строит диаграмму плотности, показывающая распределение значений числовых признаков, чтобы определить какие значения наиболее частотны и есть ли выбросы. Statistics View предоставляет статистическую сводку данных, включая такие метрики, как среднее, медиана, стандартное отклонение, минимальное и максимальное значения.

Следующий вариант обучения модели логистической регрессии, для которого первоначально при помощи компоненты Missing Value осуществляем обработку пропущенных значений в данных, а именно, включаем заполнение пропусков средними значениями, медианами или другими подходящими методами. Затем преобразуем (Category to Number) категориальные переменные в числовые значения, многие алгоритмы машинного обучения требуют числовых входных данных. Нормализуем (Normalizer (PMML) данные, приводя их к одному масштабу, так как многие алгоритмы машинного обучения чувствительны к разным диапазонам значений.

Далее Partitioning разделяет данные на обучающую и тестовую выборки. Обычно используется соотношение 80/20, что позволяет обучить модель на одной части данных и проверить ее качество на тестовой части. Узел Logistic Regression Learner обучает модель логистической регрессии, применяемый для задач классификации. Логистическая регрессия прогнозирует вероятность принадлежности объекта к определенному классу. Используем обученную модель логистической регрессии для генерации предсказаний на новых данных (Logistic Regression Predictor). Применяя обученную модель к тестовой выборке и вычисляя вероятности принадлежности объектов к определенному классу, оцениваем (Scorer) качество предсказаний, используя различные метрики (точность, precision, recall, F1-мера и др.), позволяющие оценить эффективность модели в

FreeBusta is knowledge
without borders!

различных аспектах, таких как способность правильно классифицировать объекты, минимизировать ошибки и обрабатывать несбалансированные данные.

И, для четвёртой линии потока был выбран альтернативный алгоритм обучения Decision Tree Learner, используемый для классификации или регрессии при помощи дерева решений. Дерево решений создает правила принятия решений на основе признаков данных. Здесь также с помощью узла Number to String преобразуем числовые переменные в строковые. Устанавливаем настройками компоненты Color Manager цветовую кодировку данных, полезно для визуализации. И также разделяем данные на обучающую и тестовую выборки.

После обучения модели используем обученное дерево решений для создания прогнозов. Для этого в поток добавляем компоненту Decision Tree Predictor. Переходим к оценке качества классификатора при помощи построения ROC-кривой (узел ROC Curve), что особенно полезно для задач бинарной классификации, где можно оценить компромисс между истинными положительными результатми(TP)и ложными отрицательными (FP).

Сохраняем обученную модель в формате pmml (predictive model markup language), используя компоненту PMML Writer. Формат pmml является стандартом для обмена моделями машинного обучения между различными системами, что позволяет использовать модель вне текущей платформы.

KNIME может быть полезен аналитикам данных для выполнения ETL-операций, анализа и визуализации данных, DataScientist-ам для создания и тестирования моделей машинного обучения, инженерам данных для интеграции данных из различных источников и автоматизации процессов, а также бизнес-пользователям для подготовки данных и создания отчетов.

3.5. Аналитические технологии Power BI

Power BI — это комплексный набор инструментов, включающий программные службы, приложения и соединители, которые объединяют разрозненные данные из различных источников в единое целое. Эти данные преобразуются в наглядные, интерактивные аналитические отчеты и дашборды, доступные для анализа и обмена. Источниками данных могут быть как простые таблицы Excel, так и сложные гибридные системы, включающие облачные и локальные хранилища. Power BI упрощает процесс подключения к данным, их визуализации, выделения ключевых показателей и предоставления результатов другим пользователям.

Power BI состоит из нескольких взаимодействующих компонентов:

FreeBusta is knowledge
without borders!

1) Power BI Desktop — классическое приложение для Windows, где создаются отчеты и модели данных.
2) Служба Power BI — облачная платформа (SaaS), предоставляющая доступ к отчетам через веб-интерфейс.
3) Мобильные приложения Power BI — версии для iOS, Android и Windows, позволяющие работать с данными на ходу.

Эти три основных элемента обеспечивают полный цикл работы с бизнес-аналитикой: от создания отчетов до их использования в повседневных задачах. Кроме того, Power BI предлагает два дополнительных инструмента:

1) Power BI Report Builder — средство для создания пагинированных отчетов (отчетов с разбивкой на страницы), которые можно использовать для печати или совместного доступа.
2) Сервер отчетов Power BI — локальное решение для публикации и управления отчетами, созданными в Power BI Desktop.

Типичный рабочий процесс в Power BI пользователь начинает с подключения к источникам данных через Power BI Desktop, создает модель данных и формирует отчет. Готовый отчет публикуется в службе Power BI, где становится доступным для других пользователей. Бизнес-пользователи просматривают и взаимодействуют с отчетом через веб-интерфейс службы Power BI или мобильные приложения. Этот процесс демонстрирует, как три основных компонента Power BI дополняют друг друга, обеспечивая эффективную работу с данными.

Другой важный рабочий процесс связан с пагинированными отчетами. Такие отчеты создаются с учетом формата страницы и часто используются для печати документов, таких как счета, расшифровки или регулярные отчеты. Power BI Report Builder — это специализированное приложение для создания таких отчетов. Они также могут быть опубликованы в службе Power BI для совместного использования.

Сервер отчетов Power BI позволяет развертывать отчеты внутри организации, защищенных брандмауэром, и предоставлять доступ к ним через веб-браузеры, мобильные устройства или электронную почту. Благодаря совместимости с облачной версией Power BI, переход в облако возможен в любой момент, что делает решение гибким и масштабируемым.

FreeBusta is knowledge
without borders!



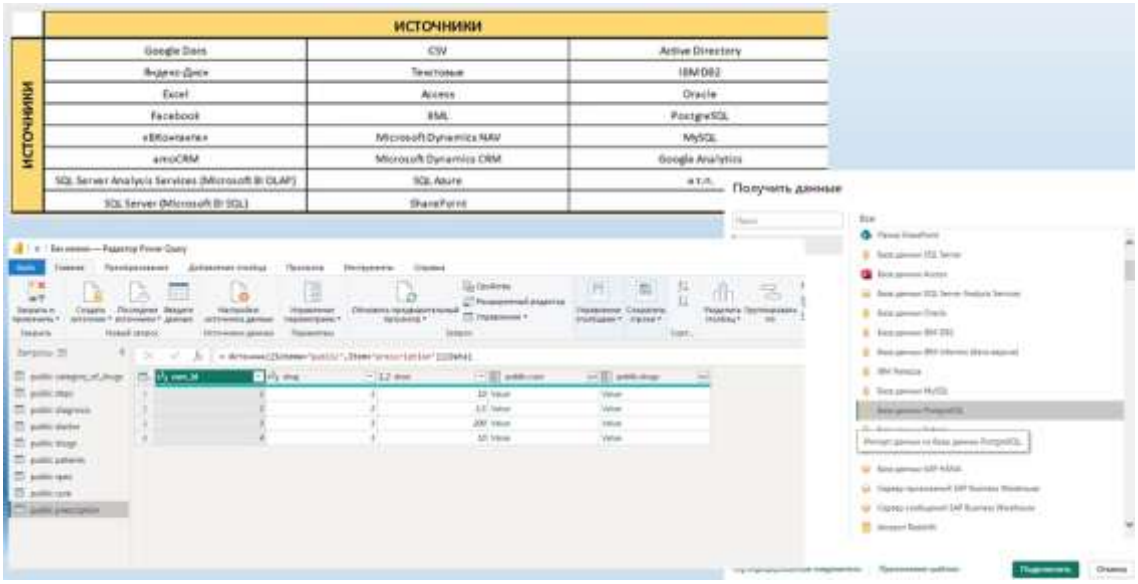


Рисунок 3.26. Работа с источниками данных в Power BI

Для работы в Power BI с данными, хранящимися в СУБД достаточно знать:

— основы моделей данных, реляционные базы данных, от правильно построенной модели зависит корректность расчетов;

— инструменты для бизнес-аналитики Microsoft, которые также используются в Excel;

— язык DAX (Data Analysis eXpressions) для суммирования, расчета среднего, количества уникальных значений и других вычислений;

— языки программирования Python и R, используемые для построения графиков, диаграмм и пр.

В Power BI Desktop во вкладке «Модель данных» выбираем две связанные таблицы и устанавливаем отношения между ними (обычно через внешние ключи). Чтобы избежать ошибок в анализе, необходимо убедиться, что отношения корректны (см. рис. 3.27).

Power Query —мощный инструмент для обработки и трансформации данных в Power BI, Excel и других продуктах Microsoft. Он позволяет пользователям подключаться к различным источникам данных, загружать данные, очищать их, выполнять различные преобразования и объединять данные из разных источников. Одна из ключевых функций Power Query — это возможность очищать и подготавливать данные перед их использованием в анализе. Это особенно важно, если данные поступают из неструктурированных или сложных источников.

Основные операции по очистке данных: автоматическое удаление строк или столбцов, содержащих только пустые значения, возможность заполнить пропуски в данных с помощью предыдущего значения, среднего значения или константы, можно изменить тип данных столбца (например, преобразовать текст в

FreeBusta is knowledge
without borders!

числовые значения), выполнять слияние и разделение столбцов. Часто требуется создать вычисляемые колонки, меры для выполнения агрегаций.

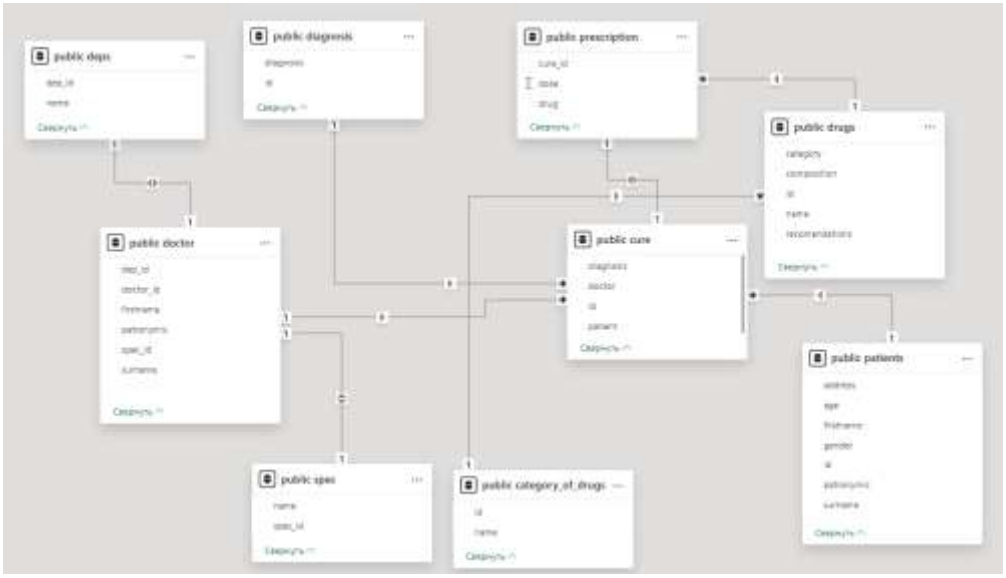


Рисунок 3.27. Модель данных в Power Pivot

В Power Query существует язык формул DAX (Data Analysis Expressions), используемый для создания сложных вычислений, фильтраций и аналитических выражений. Как раз его используем для создания мер, вычисляемых столбцов и других логических операций (см. рис. 3.28).

После создания модели данных и отчетов их можно развернуть в Power BI Service для совместного использования с другими пользователями. Для этого сохраняем файл .pbix в Power BI Desktop, загружаем его в Power BI Service и настраиваем права доступа для пользователей.

В Power BI обработанные данные можно визуализировать с помощью множества инструментов, которые помогают наглядно представить информацию. Платформа поддерживает графики различных типов, включая линейные, столбчатые и водопадные, а также диаграммы, такие как круговые, воронкообразные, точечные и комбинированные.

FreeBusta is knowledge
without borders!

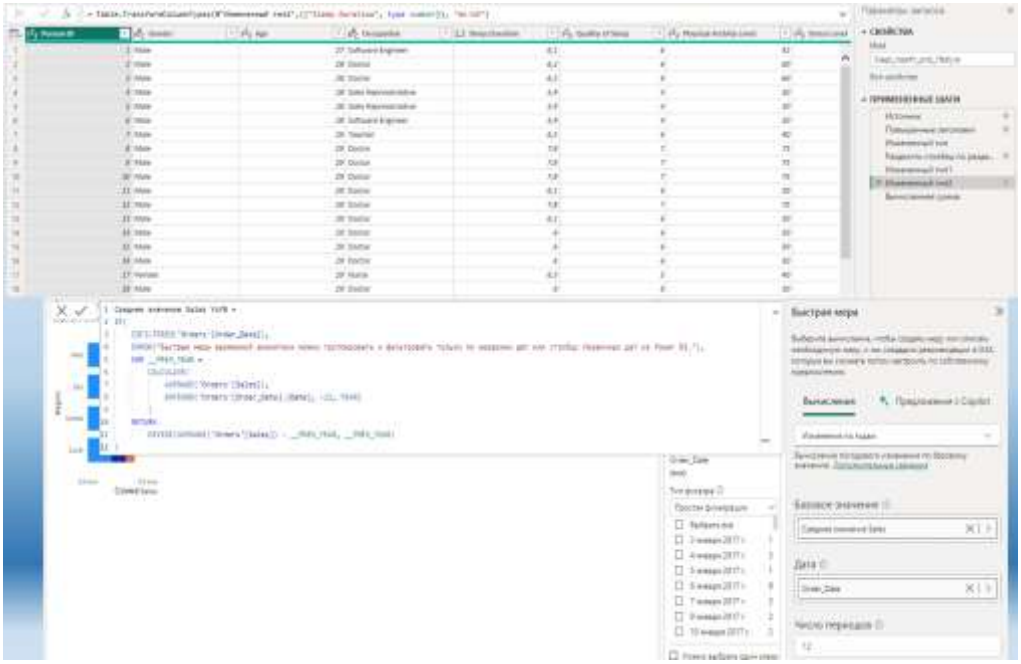


Рисунок 3.28. Создание вычислений(мер)

Для отображения ключевых показателей или метрик используются карточки и датчики, а спидометры позволяют показать значение относительно определённого диапазона. Если нужны более детальные числовые данные, можно обратиться к таблицам или матрицам, которые группируют информацию по нескольким измерениям. Географические карты, включая тепловые и tree map, помогают анализировать данные с привязкой к местоположению. Все визуализации настраиваются — можно менять цвета, шрифты, фильтры и форматы, делая их интерактивными для удобства анализа.

Дашборд (Dashboard) в Power BI — это визуальная панель, которая объединяет ключевые метрики и аналитические данные из разных отчетов. Дашборды помогают быстро получить обзорную информацию о состоянии бизнеса или конкретного процесса. Они позволяют пользователям мониторить данные в реальном времени, а также предоставлять интерактивные возможности для анализа. Дашборды создаются в Power BI Service (облачной версии Power BI), хотя данные могут быть загружены из локального файла Power BI Desktop (.pbix).

Основные компоненты дашборда:

— Плитки (Tiles) – каждая плитка на дашборде представляет собой элемент информации (например, график, число, KPI или другой визуальный объект). Плитки берутся из одного или нескольких отчетов.

— Отчеты - основные документы, созданные в Power BI Desktop. Отчеты содержат несколько визуализаций данных (графики, таблицы, карты и т.д.). Из этих отчетов можно добавлять определенные визуализации на дашборд.

FreeBusta is knowledge
without borders!

— Фильтры можно использовать на уровне дашборда или отчета, чтобы ограничивать показываемые данные в зависимости от временного периода, географии или других параметров.

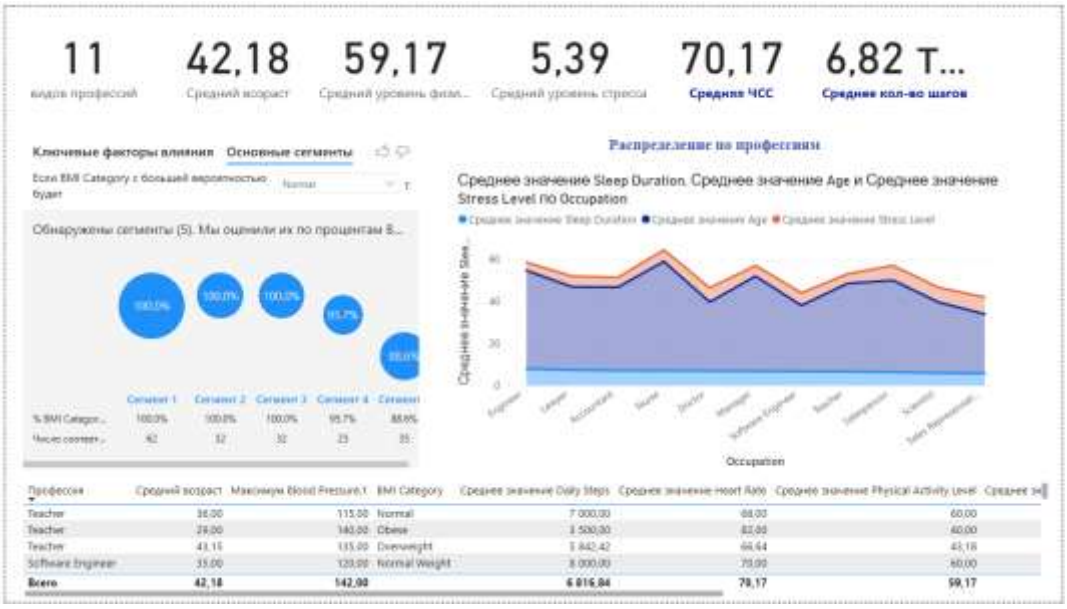


Рисунок 3.29. Пример созданного дашборда в Power BI

Power BI автоматически масштабирует содержимое дашборда под экран мобильного устройства. Однако это не всегда гарантирует идеальное отображение графиков, таблиц и других элементов. Поэтому важно проверить, как выглядит дашборд на мобильном устройстве, и при необходимости настроить его специально для мобильного просмотра.

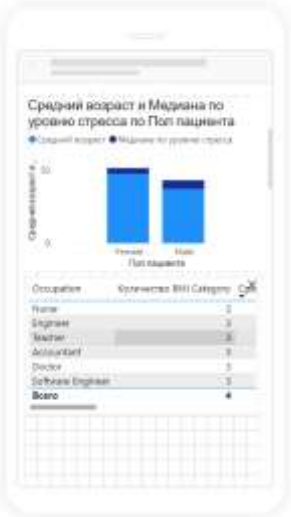


Рисунок 3.30. Отображение дашборда в мобильном приложении

Microsoft предоставляет специальное приложение Power BI Mobile, которое доступно для iOS и Android. Это приложение позволяет пользователям легко

FreeBusta is knowledge without borders!

просматривать дашборды и отчеты на своих устройствах, получать уведомления о важных изменениях в данных и даже получать доступ к Q&A.

3.6. Визуализация данных в Yandex DataLens

Yandex DataLens — это инструмент в составе Яндекс.Облака, предназначенный для анализа бизнес-показателей и тестирования гипотез. Сервис позволяет загружать, обрабатывать и визуализировать данные, объединяя их в дашборды и отчёты. Интерфейс DataLens отличается простотой и интуитивной понятностью, что делает его доступным даже для пользователей без технической подготовки. Готовые отчёты можно экспортировать или размещать на внешних платформах, предоставляя к ним открытый доступ. Также есть возможность настраивать права доступа для коллег: от просмотра до редактирования и администрирования, что упрощает совместную работу над проектами.

Чтобы начать пользоваться сервисом datalens.yandex.cloud, необходимо иметь учетную запись в Яндекс.Облаке.

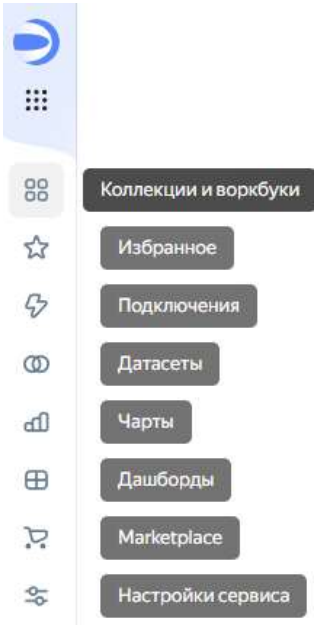


Рисунок 3.31. Панель инструментов Datalens

Интерфейс сервиса организован удобно и функционально: в левой колонке находятся инструменты, а по центру экрана расположены блоки быстрого доступа, под которыми можно найти примеры от разработчика. Основные элементы работы с данными структурированы в виде папок и разделов. Например, папка «Все объекты» содержит все ключевые элементы — подключения, датасеты, чарты и дашборды. Отдельно выделен раздел «Избранное», который позволяет быстро получить доступ к наиболее важным или часто используемым объектам.

FreeBusta is knowledge
without borders!

Работа с данными начинается с раздела «Подключения», где настраиваются параметры источников данных. Здесь поддерживаются различные коннекторы, включая ClickHouse, PostgreSQL, CSV-файлы, MS SQL Server, а также Metrica и AppMetrica, доступные как напрямую, так и через API. На основе созданных подключений формируются «Датасеты» — группы данных с описанием, которые служат основой для дальнейшей визуализации.

Следующий этап — создание «Чартов», где данные из датасетов представляются в наглядном виде: таблицах, диаграммах и графиках. В распоряжении пользователя широкий выбор типов визуализации, включая линейные, столбчатые, точечные, круговые, древовидные и диаграммы с областями, а также точечные, фоновые и тепловые карты. Завершающим шагом становится работа с «Дашбордами» — отчётами, объединяющими чарты в одном документе с возможностью применения фильтров для анализа данных.

Процесс работы с сервисом выстроен циклично: данные последовательно проходят через четыре основных объекта — от подключения источника до формирования дашборда, что наглядно демонстрируется на скриншоте.

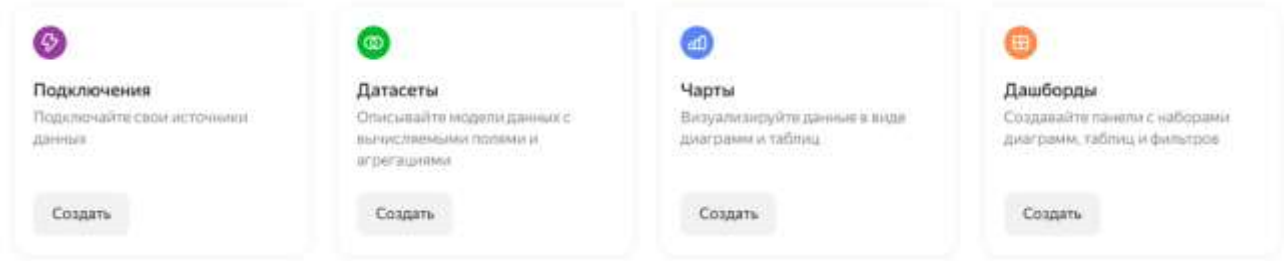


Рисунок 3.32. Блоки быстрого доступа

При необходимости данные из источника можно расширить за счет вычисляемых полей, используя различные функции. Система предоставляет широкий набор инструментов, включая операторы, функции для преобразования типов данных, работы с датой и временем, агрегатные, географические, логические, математические и строковые функции.

Чтобы приступить к работе, воспользуемся кнопками быстрого доступа и нажмем «Создать подключение». В открывшемся списке доступных коннекторов для примера остановим свой выбор на ClickHouse. На этом этапе потребуется ввести параметры подключения, такие как данные для доступа к серверу, учетные записи и дополнительные настройки, которые обеспечат корректное взаимодействие с источником данных (см. рис. 3.33). Это ключевой шаг, от которого зависит успешность загрузки и дальнейшей работы с информацией.

FreeBusta is knowledge
without borders!

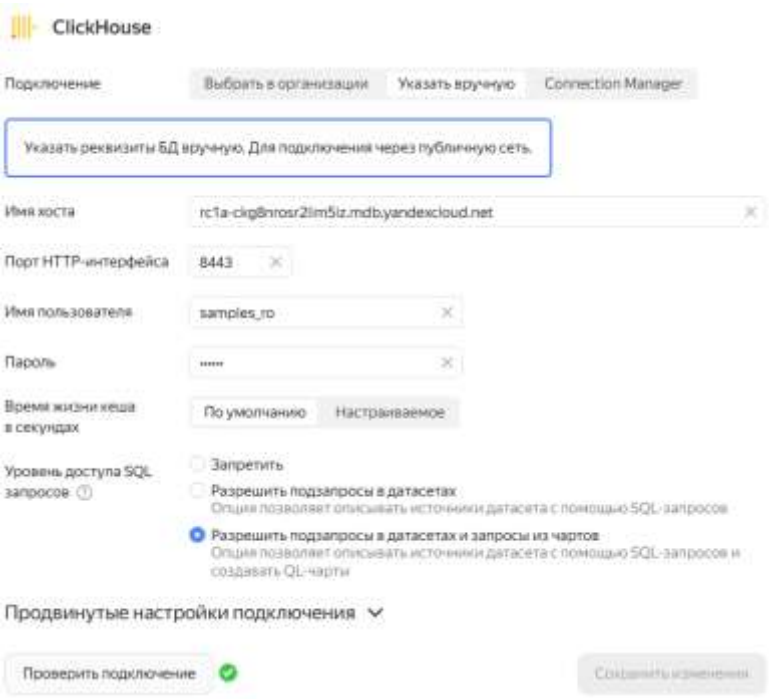


Рисунок 3.33. Параметры подключения ClickHouse

Убедившись, что в подключении активирована настройка Уровень доступа SQL-запросов → Разрешить подзапросы в датасетах и запросы из чартов, переходим к созданию QL-чарта. Вводим запрос, как показано на рис. 3.34:

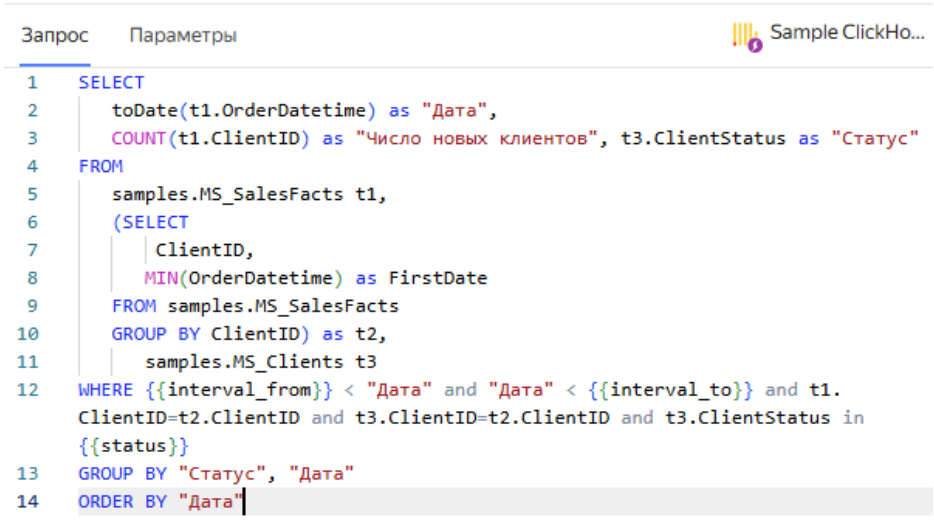


Рисунок 3.34. Запрос к данным Sample ClickHouse

Задавая следующие параметры запроса, как показано на рис. 3.35:

FreeBusta is knowledge without borders!

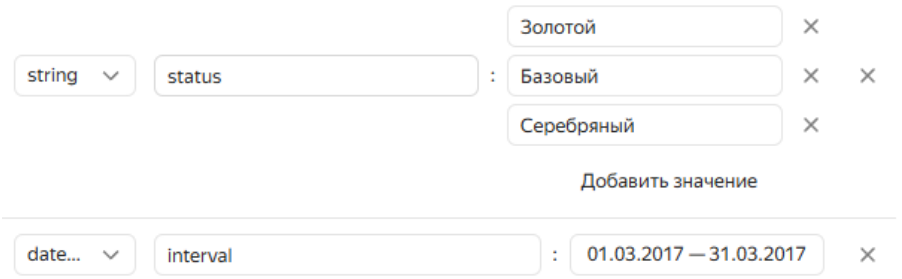


Рисунок 3.34. Вкладка параметров запроса

После того как запрос будет выполнен, результат автоматически отобразится в виде визуализации в правом окне интерфейса. Здесь можно наблюдать, как данные преобразуются в графики, таблицы или диаграммы, что позволяет наглядно оценить их структуру и содержание. Этот этап является важным для анализа и дальнейшей работы с информацией, поскольку именно визуализация помогает быстрее выявить ключевые закономерности и тренды.

После этого можно переходить к созданию дашборда, который послужит единым пространством для размещения чартов и других интерактивных виджетов. Для удобства анализа добавим селекторы — специальные элементы управления, которые позволят фильтровать данные по таким параметрам, как дата и статусы клиентов. Настроим селекторы так, чтобы они поддерживали множественный выбор статусов клиентов, а также позволяли задавать диапазон календарных дат. Это даст возможность отслеживать динамику изменений за определенные периоды, например, по годам, и глубже анализировать поведение данных. Когда все компоненты будут настроены, дашборд считается готовым к использованию. Теперь можно применять селекторы для фильтрации чартов: выберите интересующий статус клиентов или временной интервал, и визуализация мгновенно адаптируется под заданные параметры. Созданный дашборд (рис. 3.35) становится не только информативным инструментом, но и гибким средством для детального изучения данных.

Чтобы настроить доступ к дашборду или папкам, сначала необходимо открыть соответствующий объект в интерфейсе сервиса. Затем переходим в раздел «Права доступа», который обычно находится в меню настроек объекта. Здесь можно указать, какие пользователи или группы будут иметь доступ, а также определить уровень их прав: просмотр, редактирование или администрирование.

Для добавления нового пользователя вводим его email-адрес или выбираем из списка существующих учетных записей в системе. После этого назначаем

FreeBusta is knowledge
without borders!

роли, исходя из потребностей: например, роль «Просмотр» позволяет только читать данные, «Редактирование» дает возможность вносить изменения, а «Администрирование» предоставляет полный контроль над объектом.



Рисунок 3.35. Созданный дашборд с чартом по новым клиентам и селекторами

Если нужно настроить доступ к целой папке, изменения применятся ко всем объектам внутри нее — это удобно для управления группами связанных данных, таких как подключения, датасеты или дашборды. Также можно настроить общие параметры доступа, чтобы упростить управление правами для множества пользователей одновременно. После завершения настройки важно сохранить изменения и проверить их, войдя в систему под учетной записью одного из добавленных пользователей, чтобы убедиться, что права работают корректно.

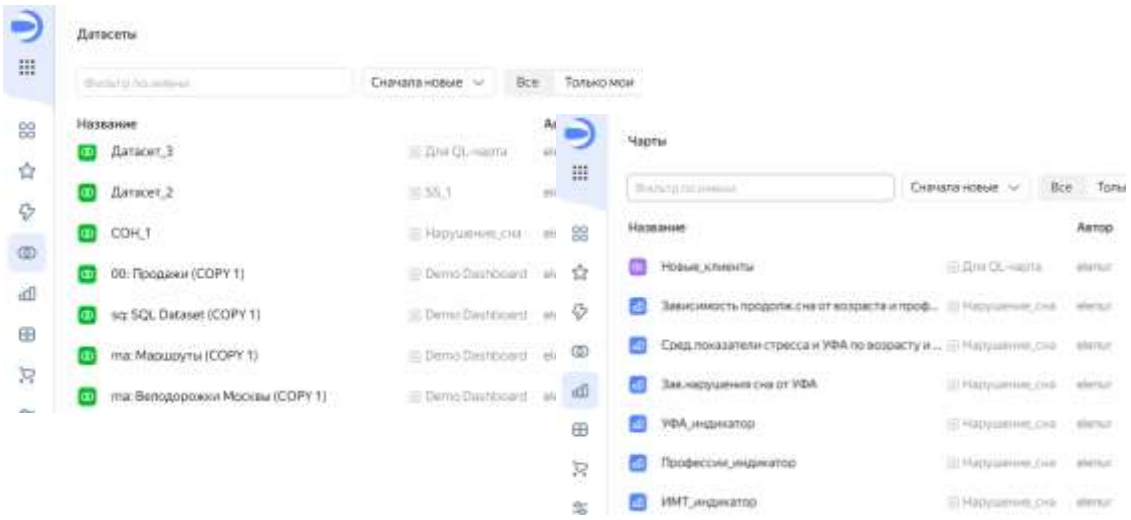


Рисунок 3.36. Датасеты и чарты для дашборда по Нарушениям сна

FreeBusta is knowledge
without borders!

Для создания дашбордов, подобным представленным на рис. 3.37, загружаем файл Sleep_health_and_lifestyle.csv через соответствующий раздел для импорта данных или создав новый датасет.

Создаём чарты:

— *таблица с метриками*, где будут отображаться ключевые показатели: средний уровень физической активности, количество групп ИМТ и количество профессий. Выбрав соответствующие столбцы из датасета, применяем агрегирующие функции (например, среднее значение или уникальное количество);

— *график зависимости продолжительности сна от возраста* с использованием диаграммы разброса (scatter plot) или точечной диаграммы, где по оси X будет возраст, по оси Y — продолжительность сна, а цветом точек обозначаем профессию;

— *таблица с детализацией по профессиям*, где будут отображаться данные о профессии, среднем уровне стресса и среднем уровне физической активности с сортировкой строк по нужным параметрам для лучшей наглядности;

— *график зависимости нарушений сна от уровня физической активности* при помощи ступенчатой диаграммы (stacked bar chart), где по оси X будут уровни физической активности, а по оси Y — количество случаев каждого типа нарушения сна (апноэ, бессонница, нет нарушений). Разделим каждую ступеньку по типам профессий для более детального анализа.

Добавляем интерактивные фильтры для улучшения навигации по данным. Например, фильтр по «Профессии» позволит выбирать конкретные профессии и видеть, как это влияет на остальные метрики, фильтр по «Возрасту» поможет анализировать данные в определенных возрастных диапазонах, фильтр по «Нарушениям сна» (апноэ, бессонница, нет нарушений) добавит возможность фокусироваться на конкретных проблемах.

Оформляем дашборд, располагая все чарты и таблицы в логичном порядке, чтобы информация была легко воспринимаемой. Например, верхнюю часть можно заполнить метриками и графиками, а нижнюю — таблицами с детальной информацией. Добавляем заголовки к каждому элементу: «Средний уровень физической активности», «Зависимость продолжительности сна от возраста и профессии» и т. д.

Настраиваем цветовую палитру так, чтобы она была согласованной и помогала различать категории (например, используйте одинаковые цвета для каждой

FreeBusta is knowledge
without borders!

профессии на всех графиках). Настраиваем взаимодействия, убедившись, что все элементы дашборда связаны между собой. Например, выбор значения в фильтре «Профессия» должен автоматически обновлять все связанные чарты и таблицы. Проверяем, как работают фильтры: при изменении одного параметра (например, возраста) должны обновляться все связанные визуализации. В завершение, выполняем публикацию и предоставляем доступ. Сохранив дашборд, проверяем его работу в режиме просмотра. Настраиваем права доступа для коллег: возможность просмотра, редактирования или администрирования дашборда. При необходимости экспортируем дашборд или публикуем его на внешних ресурсах.

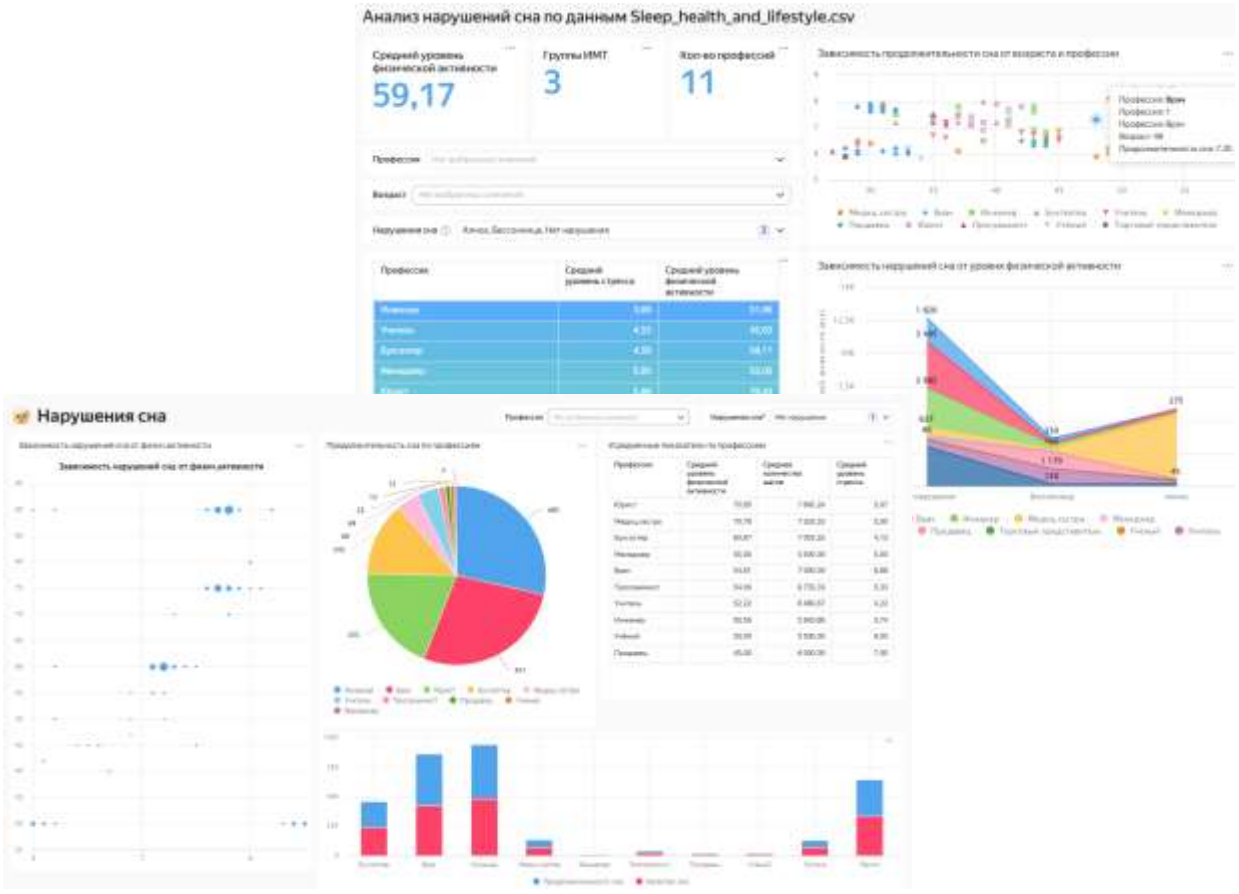


Рисунок 3.37. Примеры дашбордов по датасету sleep_health_and_life.csv

Перед окончательным использованием убеждаемся, что все элементы работают корректно, данные отображаются правильно, и интерфейс удобен для анализа. Созданный дашборд может послужить инструментом для анализа взаимосвязей между такими факторами, как профессия, возраст, уровень физической активности и качество сна.

FreeBusta is knowledge
without borders!

ЗАКЛЮЧЕНИЕ

Освоение инструментов анализа данных требует не только теоретических знаний, но и постоянной практики. В данном пособии акцент сделан на практическое применение изучаемых технологий, начиная от базовых методов обработки и заканчивая комплексными аналитическими платформами. Такой подход позволяет студентам не просто понимать принципы работы инструментов, но и уверенно применять их в реальных задачах. Мы рассмотрели, как взаимодействовать с облачными сервисами, SQL-инструментами и современными средствами автоматизации анализа данных, машинного обучения и визуализации. Познакомились с такими популярными инструментами, как H2O Flow, Altair RapidMiner, KNIME Analytics, Loginom Community, DataLens, Tableau и Power BI, а также рассмотрели способы создания интерактивных дашбордов для принятия обоснованных решений.

В учебном пособии приведены примеры использования реальных кейсов, которые помогают освоить принципы работы с данными на практике. Для каждой рассмотренной темы доступны дополнительные материалы, которые можно найти по указанным ссылкам:

— к первому разделу: https://drive.google.com/drive/folders/1BxPiBq7b6iDYi7tRlMYvXo3rjWaA4NIE?usp=sharing

— ко второму разделу: https://drive.google.com/drive/folders/100aMpPY1LKLHsveZ5K_X1fvoSoaX15az?usp=sharing

— к третьему разделу: https://drive.google.com/drive/folders/19CRaiVc0uh76Ye3NDkcCw-Ag7uBMLe_0?usp=sharing

Они помогут дополнить теоретическую часть пособия, делая процесс обучения более интерактивным и результативным.

Современный мир данных характеризуется высокой скоростью изменения технологий и методов анализа. Поэтому данное пособие нацелено не только на передачу текущих знаний, но и на формирование у студентов способности к самостоятельному освоению новых инструментов. Это позволит будущим специалистам оставаться востребованными на рынке труда, адаптируясь к новым вызовам и требованиям.

Итогом изучения материала становится комплексное понимание всего цикла работы с данными — от их сбора и обработки до анализа и визуализации результатов, что является основой успешной карьеры в области Data Science и аналитики.

FreeBusta is knowledge
without borders!

СПИСОК ИСТОЧНИКОВ И ЛИТЕРАТУРЫ

1. Маккинни Уэс Python и анализ данных: Первичная обработка данных с применением pandas, NumPy и Jupiter // ДМК Пресс, 2023. – 536 с.
2. Ежова, Л. А., Информационные технологии визуализации бизнес-информации : учебное пособие / Л. А. Ежова, О. В. Рябова, Л. В. Стацюк. — Москва : КноРус, 2024. — 257 с. — ISBN 978-5-406-12580-9. — URL: https://book.ru/book/951949
3. Платонов, А. В. Машинное обучение : учебное пособие для вузов / А. В. Платонов. — 2-е изд. — Москва : Издательство Юрайт, 2025. — 89 с. — (Высшее образование). — ISBN 978-5-534-20732-3.— URL: https://urait.ru/bcode/558662
4. Анализ данных : учебник для вузов / В. С. Мхитарян [и др.] ; под редакцией В. С. Мхитаряна. — Москва : Издательство Юрайт, 2025. — 448 с. — (Высшее образование). — ISBN 978-5-534-19964-2.— URL: https://urait.ru/bcode/560311
5. Хуттер, Ф. Введение в автоматизированное машинное обучение (AutoML) / Ф. Хуттер, Л. Коттхофф, Х. Ваншорен. - Москва : ДМК Пресс, 2023. - 257 с. - ISBN 978-5-93700-196-2. - Текст : электронный. - URL: https://znanium.ru/catalog/product/2150537
6. Танимура К. SQL для анализа данных: Расширенные методы преобразования данных для аналитики Пер. с англ. — СПб.: БХВ-Петербург, 2024. — 384 с.
7. Бен-Ган И. Оконные функции в T-SQL/ пер. с англ. А.Ю. Гинько. – М.: ДМК Пресс, 2022. – 344с.
8. Кук, Д. Машинное обучение с использованием библиотеки H20 / Д. Кук ; пер. с англ. А.Б. Огурцова. - Москва : ДМК Пресс, 2018. - 250 с. - ISBN 978-5-97060-508-0. - Текст : электронный. - URL: https://znanium.com/catalog/product/1028135

FreeBusta is knowledge without borders!



Сведения об авторах

Нурматова Елена Вячеславовна, к.т.н., доцент кафедры КБ-3 «Разработка программных решений и системное программирование». Рабочий телефон: +7 499 681-33-56 (доб. 4066)

Зайцев Евгений Игоревич, к.т.н., доцент кафедры КБ-4 «Цифровые технологии обработки данных». Рабочий телефон: +7 499 681-33-56 (доб. 6803)

FreeBusta is knowledge
without borders!

